

INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA

OmniAI Gateway

Relatório Final de Projeto

Guilherme Coutinho

Nº 50467

A50467@alunos.isel.pt

André Nunes

Nº 51766

A51766@alunos.isel.pt

Orientador: Pedro Félix

pedro.felix@isel.pt

Engenharia Informática e de Computadores

1 de junho de 2026

Resumo

A ausência de um protocolo comum na comunicação com Modelos de Linguagem de Grande Escala (LLMs) obriga as aplicações a integrarem diferentes interfaces de acesso e implementações particulares para a invocação de ferramentas externas. Atualmente cada fornecedor (como **OpenAI** [1], **Anthropic** [2] e **Gemini** [3]) impõe as suas próprias estruturas de dados, ciclos de vida de *streaming* e padrões para a invocação de ferramentas (*tool calling*) [4] [5]. Para resolver esta fragmentação tecnológica, este projeto propõe o desenvolvimento do **OmniAI SDK**, um *Software Development Kit* construído em **Kotlin Multiplatform (KMP)** [6]. O objetivo principal desta biblioteca é fornecer a infraestrutura base necessária para instanciar e configurar de forma rápida uma **OmniAI Gateway** (um ponto de entrada centralizado dedicado ao acesso de inferência, segurança, observabilidade e outros). O **OmniAI SDK** é baseado nos princípios da Arquitetura Hexagonal (*Ports and Adapters*) [7], este isola a lógica de domínio e suporta a comunicação bidirecional compatível com os padrões das APIs de referência, nomeadamente **OpenAI** [1], **Anthropic** [2] e **Gemini** [3]. O sistema implementa uma *pipeline* extensível e configurável, inspirada no modelo de filtros e cadeia de filtros dos **Servlets** [8] [9], que executa *interceptors* pré-construídos para autorização, autenticação, métricas, *rate limiting*, *circuit breaker* e *fallback*, podendo ser adicionados mais *interceptors* customizados pelo utilizador do **OmniAI SDK**. Adicionalmente, o *Software Development Kit* prepara um módulo **MCP Broker** para evoluir a **OmniAI Gateway** de uma *gateway* de inferência e torná-la numa *AI Gateway* completa, adicionando a gestão de ferramentas externas à **OmniAI Gateway** utilizando o **Model Context Protocol (MCP)** [10]. Distribuído de forma multiplataforma para ambientes **JVM**, via **Maven**, e **Node.js/TypeScript**, via **NPM**, o **OmniAI SDK** foi validado através da construção de uma **OmniAI Gateway**, um *Proof of Concept* que utiliza a biblioteca para demonstrar a criação de uma *gateway* real. A avaliação demonstra que a solução minimiza o acoplamento tecnológico e o esforço de integração, garantindo resiliência, escalabilidade e centralização na utilização de clientes de IA, como o **Claude Code** [11], entre outros.

Abstract

The absence of a common protocol for communicating with Large Language Models (LLMs) forces applications to integrate diverse access interfaces and bespoke implementations for external tool invocation. Currently, each provider (such as **OpenAI** [1], **Anthropic** [2], and **Gemini** [3]) imposes its own data structures, streaming lifecycles, and tool calling patterns [4] [5]. To address this technological fragmentation, this project proposes the development of the **OmniAI SDK**, a Software Development Kit built using **Kotlin Multiplatform (KMP)** [6]. The primary objective of this library is to provide the foundational infrastructure required to rapidly instantiate and configure an **OmniAI Gateway** (a centralized entry point dedicated to inference access, security, observability, and more). Based on the principles of Hexagonal Architecture (*Ports and Adapters*) [7], the **OmniAI SDK** isolates domain logic and supports bidirectional communication compatible with reference API standards, namely **OpenAI** [1], **Anthropic** [2], and **Gemini** [3]. The system implements an extensible and configurable *pipeline*, inspired by the Servlet filter and filter chain model [8] [9], which executes pre-built *interceptors* for authorization, authentication, metrics, *rate limiting*, *circuit breaker*, and *fallback*, while allowing the user of the **OmniAI SDK** to add custom interceptors. Additionally, the Software Development Kit features an **MCP Broker** module to evolve the **OmniAI Gateway** from a simple inference gateway into a comprehensive *AI Gateway*, adding external tool management to the **OmniAI Gateway** using the **Model Context Protocol (MCP)** [10]. Distributed as a multiplatform solution for **JVM** environments, via **Maven**, and **Node.js/TypeScript**, via **NPM**, the **OmniAI SDK** was validated through the construction of an **OmniAI Gateway**, a Proof of Concept that leverages the library to demonstrate a real-world gateway deployment. The evaluation demonstrates that the solution minimizes technological coupling and integration effort, ensuring resilience, scalability, and centralization across AI clients, such as **Claude Code** [11], among others.

Índice

1	Introdução	5
1.1	Contexto	5
1.2	Motivação e Definição do Problema	6
1.3	Objetivos e Proposta de Solução	7
1.4	Estrutura do Documento	8
2	Estudo Prévio	9
2.1	Análise das APIs de Inferência	9
2.1.1	Construção do Pedido	10
2.1.2	Processamento da Resposta	12
2.1.3	Divergências na Padronização de Esquemas de Validação	14
2.1.4	Conclusão do Estudo das APIs de Inferência	14
2.2	Model Context Protocol (MCP)	14
3	Modelação do Domínio Comum	16
3.1	Visão Global do Domínio	16
3.2	Estrutura do Domínio Comum	17
3.2.1	CommonRequest	17
3.2.2	CommonResponse e CommonResponseEvent	19
3.3	TypedMap e Extensibilidade do Domínio	21
4	Arquitetura e Desenho do Sistema	23
4.1	Arquitetura Hexagonal (Ports & Adapters)	25
4.1.1	Contracts	26
4.1.2	Inbounds	26
4.1.3	Outbounds	26
4.1.4	HttpTransportClient	27
4.1.5	Dispatcher	27
4.2	Organização do SDK	27
5	Implementação e Evolução Técnica	29
5.1	Stack Tecnológica e Metodologias	29
5.2	A Primeira Iteração da Gateway	30
5.3	Decisões de Desenho e Alternativas Descartadas	31

5.4	Evolução Arquitetural: De <i>Inference Service</i> a <i>Dispatcher</i>	31
5.5	Implementação da Camada HTTP : <i>gateway-ktor-server</i>	32
5.6	Implementação do <code>HttpTransportClient</code> em Ktor	33
5.7	Implementações Inbound e Outbound	34
5.8	Translators de Entrada (Inbound)	34
5.8.1	OpenAI Inbound Translator	34
5.8.2	Anthropic Inbound Translator	36
5.8.3	Gemini Inbound Translator	38
5.9	Translators de Saída (Outbound)	41
5.9.1	OpenAI Outbound Translator	41
5.9.2	Anthropic Outbound Translator	43
5.9.3	Gemini Outbound Translator	44
5.10	Evolução para a Pipeline de Interceptors	46
5.11	Arquitetura Interna dos Interceptors	48
5.11.1	Interceptor de Telemetria e Observabilidade	49
5.11.2	Interceptor de Autenticação	51
5.11.3	Interceptor de Autorização	53
5.11.4	Interceptor de Rate Limiting	55
5.11.5	Interceptor de Circuit Breaker	55
5.11.6	Interceptor de Fallback	56
5.11.7	Interceptor de Logging e Tracing	57
5.11.8	MCP Broker e Ferramentas Externas	58
5.12	Distribuição Multiplataforma	59
6	Proof of Concepts e Validação	61
6.1	Validação do <i>Proof of Concept</i> da OmniAI Gateway	61
6.2	Validação com REST Client	62
6.3	Validação de Segurança com Logto	62
6.4	Validação de Observabilidade	63
6.5	Validação com Aplicações Cliente	63
6.5.1	Execução do Claude Code com autenticação Logto	63
6.6	Limites da Validação	64
7	Conclusões e Trabalho Futuro	65
7.1	Conclusões	65
7.2	Melhorias Futuras e Escalabilidade	66
A	Exemplos JSON das APIs de Inferência	67
A.1	Pedidos (<i>Requests</i>)	67
A.1.1	OpenAI (formato compatível)	67
A.1.2	Anthropic	69
A.1.3	Google Gemini	71
A.2	Respostas (<i>Responses</i>)	74

A.2.1	OpenAI (formato compatível)	74
A.2.2	Anthropic	77
A.2.3	Google Gemini	79
B	Histórico de Planeamento e Riscos	83
B.1	Riscos	83
B.2	Planeamento	85

Lista de Figuras

1.1	Acoplamento direto entre cliente e um fornecedor de inferência	6
1.2	Multiplicação de conexões com chaves de API descentralizadas	6
1.3	Cliente decide trocar de fornecedor	6
1.4	Centralização com OmniAI Gateway	7
2.1	Estruturas JSON esquemáticas e simplificadas de pedidos para cada fornecedor. .	11
2.2	Estruturas JSON esquemáticas e simplificadas de respostas para cada fornecedor.	13
3.1	Fluxo de normalização entre contratos externos e domínio comum (OmniAi-SDK)	16
3.2	Estrutura de classes do CommonRequest	17
3.3	Estrutura de classes do CommonResponse	19
3.4	Utilização da TypedMap para transportar atributos extensíveis	22
4.1	Arquitetura Top Level: O OmniAI SDK utilizado para instanciar uma OmniAI Gateway , abstraindo integrações externas padronizadas.	24
4.2	Visão da integração entre Ktor , <i>inbounds</i> , <i>pipeline</i> , <i>interceptors</i> , <i>outbounds</i> e HTTP client no OmniAI SDK	24
5.1	Arquitetura de Tradução e Fluxo de Dados entre Contratos e Domínio Comum .	34
5.2	Visão conceptual da <i>pipeline</i> de <i>interceptors</i>	47
5.3	Fluxo interno de processamento e lógica de observabilidade para pedidos unários e <i>streaming</i>	50
5.4	Observabilidade e métricas operacionais da OmniAI Gateway	51
5.5	Sequência OIDC : descoberta, JWKS e cache de chaves	52
5.6	Fluxo interno do <i>interceptor</i> de autenticação	53
5.7	Arquitetura do <i>interceptor</i> de autorização: separação entre PEP e PDP	54
5.8	Visão geral do fluxo de <i>Tool Calling</i> [12].	59
6.1	Cenários de validação do <i>Proof of Concept</i>	62

Capítulo 1

Introdução

1.1 Contexto

Os Modelos de Linguagem de Grande Escala (*Large Language Models – LLMs*) [13] tornaram-se componentes relevantes no desenvolvimento de aplicações baseadas em inteligência artificial. Um LLM é um modelo treinado com grandes volumes de texto, capaz de interpretar linguagem natural, gerar respostas e apoiar tarefas como sumarização, classificação, programação assistida, pesquisa semântica. Uma funcionalidade também oferecida por estes modelos é o *tool calling* [4] [5]. O *tool calling* permite que os modelos não se limitem ao seu conhecimento estático, permitindo-lhes realizar um pedido de interação com sistemas externos através de uma resposta estruturada. Este pedido obedece a um formato específico, definido previamente no momento em que as ferramentas são enviadas à API de inferência.

O ciclo de vida de um modelo divide-se em duas fases principais: treino e inferência. O treino corresponde ao processo de aprendizagem a partir de grandes conjuntos de dados, exigindo elevados recursos computacionais. A inferência corresponde à utilização do modelo já treinado para gerar respostas a novos pedidos. Atualmente, a maioria das aplicações integra LLMs através de APIs de inferência disponibilizadas por fornecedores externos.

A comunicação com estas APIs é normalmente realizada usando o protocolo **HTTP** com representação em JSON, tanto nos pedidos como nas respostas. Antes de serem processados pelos modelos, os textos são convertidos em *tokens*, pequenas unidades de informação que permitem ao modelo representar e manipular sequências de entrada e saída [14]. Como a resposta é gerada de forma incremental, muitas APIs suportam *streaming*, permitindo enviar fragmentos da resposta ao cliente à medida que são produzidos.

Existem vários fornecedores relevantes, incluindo **OpenAI** [1], **Anthropic** [2], **Google Gemini** [3] e **Groq** [15]. Embora todos disponibilizem APIs **HTTP** e estruturas JSON, cada fornecedor define interfaces próprias, campos específicos, regras de autenticação e modelos distintos para *tool calling*. A integração direta com vários fornecedores obriga, por isso, as aplicações a conhecerem detalhes internos de cada API.

Ao mesmo tempo, o uso de LLMs evoluiu de interações simples para sistemas baseados em agentes (*agentic workflows*) [16]. Nestes sistemas, o modelo não se limita a devolver texto, pode também devolver instruções para chamadas a ferramentas externas, interpretar resultados intermédios e produzir uma resposta final com base nesses dados. O **Model Context Protocol**

(MCP) surgiu como proposta de normalização para a comunicação entre modelos, aplicações e ferramentas externas [10].

1.2 Motivação e Definição do Problema

As Figuras 1.1, 1.2 e 1.3 ilustram o acoplamento direto entre clientes e fornecedores de inferência, bem como a dificuldade que os clientes tem em trocar de fornecedor devido a todo acoplamento que existe.




Figura 1.1: Acoplamento direto entre cliente e um fornecedor de inferência




Figura 1.2: Multiplicação de conexões com chaves de API descentralizadas




Figura 1.3: Cliente decide trocar de fornecedor

A existência de múltiplos fornecedores de LLMs e a ausência de um protocolo comum implicam diferentes interfaces de acesso aos modelos, estruturas específicas de pedidos e respostas, modelos distintos de contabilização de *tokens*, custos variáveis e implementações particulares para invocação de funções externas (ver Figuras 1.1–1.3). Por exemplo, a API da **OpenAI** [1] organiza a interação em torno de *chat completions* e *tool calls*; a API da **Anthropic** [2] utiliza uma arquitetura baseada em messages e blocos de conteúdo; e a API do **Gemini** [3] estrutura a geração através de contents, parts, function declarations e configurações de geração próprias.

Estas diferenças criam acoplamento entre as aplicações cliente e os fornecedores, denominado de *vendor lock-in*. Sempre que uma aplicação pretende trocar de modelo, suportar mais do que um fornecedor, adicionar um mecanismo de *fallback* ou integrar ferramentas externas, torna-se necessário duplicar ou reimplementar lógica de tradução, autenticação, tratamento de erros e interpretação de respostas. Esta duplicação ou reimplementação aumenta a complexidade e dificulta a evolução do sistema, um problema recorrente em sistemas que combinam lógica de aplicação com integrações externas especializadas [17].

Para além da fragmentação dos contratos, existem preocupações operacionais e de segurança. Uma aplicação que comunica diretamente com vários fornecedores precisa de gerir chaves de API, quotas, limites de utilização, métricas, auditoria, políticas de acesso e proteção contra falhas de terceiros. Sem uma camada intermédia, estas preocupações ficam espalhadas por vários pontos do sistema, tornando mais difícil aplicar regras consistentes de autenticação, autorização, observabilidade e resiliência.

O problema central deste projeto é, assim, a ausência de uma camada de abstração capaz de separar as aplicações cliente das particularidades de cada fornecedor de LLMs, mantendo simultaneamente suporte para segurança, monitorização, *tool calling* e integração dinâmica com ferramentas externas.

1.3 Objetivos e Proposta de Solução




Figura 1.4: Centralização com **OmniAI Gateway**

A solução proposta evoluiu para a construção de um **OmniAI SDK**, isto é, uma biblioteca reutilizável que permite instanciar uma **OmniAI Gateway**. A **Gateway** funciona como ponto de entrada único para aplicações cliente, centralizando o acesso a APIs de inferência, ferramen-

tas externas e mecanismos globais de segurança e operação. Esta abordagem aproxima-se do padrão de API **Gateway** [18] e, no contexto específico de modelos de IA, do padrão de AI **Gateway** enquanto camada centralizada de acesso a modelos [19,20]. Embora existam soluções relacionadas, como LiteLLM e OpenRouter [21,22], o foco deste projeto está na construção de um **SDK** extensível, configurável e validado por uma **Gateway Proof of Concept** própria.

O **OmniAI SDK** foi desenvolvido em **Kotlin Multiplatform**, permitindo partilhar o domínio e vários componentes entre *targets* diferentes e preparar a distribuição para **JVM** e **JavaScript/Node.js** [23]. Esta decisão torna possível disponibilizar a biblioteca em ecossistemas distintos: via **Maven** para aplicações **JVM/Kotlin** e via **NPM** para ambientes **Node.js/TypeScript**.

A arquitetura do **OmniAI SDK** foi organizada segundo os princípios da Arquitetura Hexagonal, também conhecida como *Ports and Adapters* [7]. O domínio comum fica isolado de contratos externos, enquanto os *inbound adapters* traduzem pedidos de clientes compatíveis com **OpenAI**, **Anthropic** ou **Gemini** para o modelo comum, e os *outbound adapters* traduzem o modelo comum para chamadas reais aos fornecedores.

Para tornar a solução configurável e escalável, foi criada uma *pipeline* interna de *interceptors*, inspirada no modelo de filtros e cadeia de filtros dos **Servlets** [8] [9]. Esta *pipeline* permite injetar comportamentos específicos tanto antes como após a chamada ao fornecedor de inferência ou ao próximo *interceptor* na *pipeline*, incluindo autenticação, autorização, métricas, *rate limiting*, *circuit breaker*, *fallback* e *logging*.

Para garantir que a **OmniAI Gateway** atue como uma peça de infraestrutura completa de inteligência artificial, a arquitetura incorpora um **MCP Broker**. Este módulo permite a exposição e centralização de múltiplas ferramentas externas através do **Model Context Protocol** (MCP) [10].

1.4 Estrutura do Documento

Este documento encontra-se organizado de forma progressiva, partindo do problema de integração e avançando até à validação da solução construída. O Capítulo 2 apresenta o estudo prévio: primeiro a análise comparativa das APIs de inferência e depois o estudo do **Model Context Protocol**. O Capítulo 3 descreve a modelação do domínio comum, explicando como os conceitos observados no estudo foram transformados em estruturas como **CommonRequest**, **CommonResponse**, **CommonResponseEvent**, **CommonTool** e **TypedMap**. O Capítulo 4 descreve a arquitetura do **OmniAI SDK** e do *Proof of Concept*, incluindo a visão top-level, a Arquitetura Hexagonal, os módulos, os *contracts*, os *inbounds*, os *outbounds*, o *dispatcher*, a DSL e o cliente **HTTP**. O Capítulo 5 detalha a implementação técnica e a evolução do sistema, com foco na separação entre **OmniAI SDK** e **OmniAI Gateway**, na *pipeline* de *interceptors*, nos mecanismos de segurança, observabilidade e resiliência, no **MCP Broker** e na distribuição multiplataforma. O Capítulo 6 apresenta as provas de conceito efetivamente realizadas no *Proof of Concept OmniAI Gateway*. O Capítulo 7 sintetiza as conclusões, limitações e linhas de evolução futura. O Capítulo 8 regista o histórico de planeamento e os principais riscos considerados durante o desenvolvimento.

Capítulo 2

Estudo Prévio

2.1 Análise das APIs de Inferência

O estudo inicial comparou APIs de inferência, nomeadamente os líderes de mercados, como as da **OpenAI** [1], **Anthropic** [2] e **Gemini** [3], para este estudo, utilizou-se o **Ollama** para analisar a API da **Anthropic**, o **Groq** para a da **OpenAI**, e o **AI Studio** da própria Google para avaliar a API do **Gemini**.

Este estudo não teve apenas um papel de descrever as APIs, mas sim servir como base e ponto de partida para observar os conceitos que podiam ser normalizados no **OmniAI SDK** e os pontos onde a normalização teria de preservar extensões específicas de cada fornecedor. Para esse efeito, foram executados e documentados pedidos de geração simples, pedidos com *streaming*, pedidos com *tool calling*, respostas com contabilização de *tokens* e casos de configuração de geração. É de notar que o uso de vídeos, imagens e outros formatos suportados por estas APIs seria interessante, mas aumentaria demasiado o escopo do estudo e do projeto.

O estudo das APIs de inferência mostrou que estas partilham de diversos conceitos semelhantes, mas permitem a utilização dos mesmos de maneira diferente. A **OpenAI** organiza a interação em torno de `chat/completions`, com `messages`, `choices`, `tool_calls` e eventos incrementais baseados em `delta` [1]. A **Anthropic** usa uma API de `messages`, onde o `system prompt` está no nível de topo, o campo `max_tokens` é obrigatório, e o conteúdo da resposta é uma lista de blocos como `text`, `tool_use` ou `thinking` [2]. A **Gemini** modela o pedido como `contents` compostos por `parts`, agrupa parâmetros em `generationConfig`, representa ferramentas por `functionDeclarations` e introduz conceitos próprios como *thought signatures* e `thinkingConfig` [3]. Ao longo deste capítulo as diferenças e semelhanças irão ficar mais claras.

2.1.1 Construção do Pedido

Construção do Pedido	OpenAI	Anthropic	Gemini
Autenticação	Cabeçalho Authorization: Bearer <TOKEN> .	Cabeçalho x-api-key e obrigatoriedade de anthropic-version .	Cabeçalho x-goog-api-key ou parâmetro ?key= no URI.
URI (<i>Endpoint</i>)	Fixo por tarefa (e.g., <code>.../v1/chat/completions</code>).	Fixo para mensagens (<code>.../v1/messages</code>).	Dinâmico, acoplando modelo e método (<code>.../models/{model}:{method}</code>).
Identificação do Modelo	Definido via propriedade "model" na raiz do <i>payload</i> JSON.	Definido via propriedade "model" na raiz do <i>payload</i> JSON.	Injetado dinamicamente no próprio URI de chamada HTTP .
Estrutura do Histórico	<i>Array messages</i> contendo objetos com role e content .	<i>Array messages</i> contendo objetos com role e content .	<i>Array contents</i> contendo objetos com role e <i>array parts</i> .
Conteúdo da Mensagem	O content pode ser <i>string</i> simples ou <i>array</i> polimórfico.	O content exige estritamente um <i>array</i> de blocos estruturados.	O conteúdo divide-se num <i>array parts</i> de objetos tipados.
Instruções de Sistema	Tratadas como mensagem inicial com role: "system" .	Declaradas na propriedade isolada "system" na raiz do <i>payload</i> .	Declaradas no objeto isolado "system_instruction" na raiz.
Parâmetros de Geração	Propriedades soltas na raiz (e.g., temperature , max_tokens).	Propriedades soltas na raiz ("max_tokens" é obrigatório).	Agrupados num único objeto configuracional ("generationConfig").
Declaração de Ferramentas	Propriedade tools[].function contendo parameters .	Propriedade tools[] contendo input_schema .	Propriedade tools[].functionDeclarations contendo parameters .
Ativação de <i>Streaming</i>	Propriedade "stream": true na raiz do corpo JSON.	Propriedade "stream": true na raiz do corpo JSON.	URI distinto (streamGenerateContent) com parâmetro ?alt=sse ; não existe campo no corpo.
Configuração de Raciocínio	Suporte nativo e automático na família de modelos o1/o3 ; sem campo dedicado de ativação.	Objeto "thinking" na raiz, com type e budget_tokens para controlar o orçamento.	Objeto thinkingConfig dentro de generationConfig , com opções como thinkingLevel e include_thoughts .
Saídas Estruturadas	Controladas via "response_format" na raiz (e.g., {"type": "json_object"}).	Implementadas forçando uma ferramenta dedicada via tool_choice para extrair dados.	Definidas via responseMimeType e responseJsonSchema dentro de generationConfig .

Tabela 2.1: Mapeamento técnico da estrutura de pedidos e configuração (*Requests*).

Com base nos pedidos executados durante o estudo, foi possível identificar os campos JSON mais relevantes de cada fornecedor. A Figura 2.1 apresenta os esqueletos estruturais dessas mensagens, evidenciando as diferenças de organização e de nomenclatura entre os três fornecedores. Os exemplos JSON completos dos pedidos encontram-se no Apêndice A.1.

OpenAI Request	Anthropic Request	Gemini Request
<pre>{ "model": "gpt-4o", "messages": [{ "role": "system", "content": "..." }, { "role": "user", "content": "..." }], "temperature": 0.7, "max_tokens": 150, "tools": [{ "type": "function", "function": { "name": "func", "parameters": {...} } }], "tool_choice": "auto", "stream": false }</pre>	<pre>{ "model": "claude-3-5-sonnet", "system": "...", "messages": [{ "role": "user", "content": [{ "type": "text", "text": "..." }] }], "max_tokens": 150, "temperature": 0.7, "tools": [{ "name": "func", "input_schema": {...} }], "tool_choice": { "type": "auto" } }</pre>	<pre>URI: models/{model}:{method} { "contents": [{ "role": "user", "parts": [{"text": "..."}] }], "systemInstruction": { "parts": [{"text": "..."}] }, "generationConfig": { "temperature": 0.7, "maxOutputTokens": 150 }, "tools": [{ "functionDeclarations": [{ "name": "func", "parameters": {...} }] }] }</pre>

Figura 2.1: Estruturas JSON esquemáticas e simplificadas de pedidos para cada fornecedor.

A análise dos campos de pedido revela que, embora os três fornecedores compartilhem conceitos equivalentes, cada um organiza o corpo JSON de forma distinta. A **OpenAI** [1] e a **Anthropic** [2] colocam a maioria dos parâmetros de configuração como propriedades soltas na raiz do objeto, enquanto a **Gemini** agrupa-os dentro de `generationConfig` [3]. A diferença mais notável está na identificação do modelo. Neste caso, a **OpenAI** e a **Anthropic** incluem-na no corpo do pedido, enquanto a **Gemini** a incorpora diretamente no URI da chamada **HTTP**, tornando o *endpoint* dinâmico. O *system prompt* também diverge consideravelmente: a **OpenAI** trata-o como uma mensagem com o papel `system` [1], a **Anthropic** eleva-o a uma propriedade de topo [2], e a **Gemini** define-o através de um objeto `system_instruction` separado [3]. Estas diferenças tornam evidente que uma tradução superficial dos nomes dos campos seria insuficiente para construir uma abstração e um domínio comum que seja capaz de cobrir os três fornecedores de inferência.

2.1.2 Processamento da Resposta

Processamento da Resposta	OpenAI	Anthropic	Gemini
Estrutura Raiz da Resposta	Objeto <code>choices[]</code> contendo <code>message</code> com <code>role</code> e <code>content</code> .	Diretamente na raiz: <code>role</code> , <code>content[]</code> , <code>stop_reason</code> e <code>usage</code> .	Objeto <code>candidates[]</code> contendo <code>content</code> com <code>role</code> e <code>parts[]</code> .
Invocação pelo Modelo (<i>Tool Call</i>)	Retorna <code>tool_calls[]</code> com <code>arguments</code> em <i>string</i> JSON serializada.	Retorna um bloco <code>type: "tool_use"</code> com <code>input</code> em JSON nativo.	Retorna uma <code>part</code> contendo <code>functionCall</code> com <code>args</code> (JSON nativo).
Resposta da Ferramenta	Adicionada como nova mensagem com <code>role: "tool"</code> e <code>tool_call_id</code> .	Adicionada sob <code>role: "user"</code> num bloco <code>type: "tool_result"</code> com <code>tool_use_id</code> .	Adicionada como nova mensagem contendo <code>functionResponse</code> com <code>name</code> e <code>response</code> .
Razão de Paragem	Campo <code>finish_reason</code> com valores como <code>"stop"</code> , <code>"tool_calls"</code> ou <code>"length"</code> .	Campo <code>stop_reason</code> com valores como <code>"end_turn"</code> , <code>"tool_use"</code> ou <code>"max_tokens"</code> .	Campo <code>finishReason</code> com valores como <code>"STOP"</code> ou <code>"MAX_TOKENS"</code> (notação em maiúsculas).
Saídas Estruturadas	Controladas via propriedade <code>"response_format"</code> na raiz.	Implementadas forçando uma ferramenta dedicada via <code>tool_choice</code> .	Definidas via <code>responseMimeType</code> e <code>responseJsonSchema</code> .
Comportamento <i>Streaming</i>	Ativado via <code>stream: true</code> ; eventos <code>SSE</code> com formato <code>delta</code> .	Ativado via <code>stream: true</code> ; eventos <code>SSE</code> fortemente tipados (<code>message_start</code> , <code>content_block_delta</code> , etc.).	Consumido através de um <code>endpoint</code> distinto com parâmetro <code>?alt=sse</code> ; cada evento contém um objeto de resposta parcial completo.
Metadados de Raciocínio	Suporte nativo e automático na família de modelos <code>o1/o3</code> .	Ativado via <code>"thinking"</code> ; devolvido num bloco <code>"thinking"</code> com <code>signature</code> .	Ativado via <code>thinkingConfig</code> ; suporta entrega de <code>thoughtSignature</code> nos <code>parts</code> .
Contabilização de <i>Tokens</i>	Objeto <code>usage</code> (campos <code>prompt_tokens</code> , <code>completion_tokens</code> , <code>total_tokens</code>).	Objeto <code>usage</code> (campos <code>input_tokens</code> , <code>output_tokens</code> ; sem <code>total</code> explícito).	Objeto <code>usageMetadata</code> (<code>promptTokenCount</code> , <code>candidatesTokenCount</code> , <code>totalTokenCount</code> , <code>thoughtsTokenCount</code>).
Identificador da Resposta	Campo <code>id</code> (e.g., <code>"chatcmpl-31"</code>) e metadados <code>object</code> , <code>created</code> .	Campo <code>id</code> (e.g., <code>"msg_01Xf..."</code>) e campo <code>type: "message"</code> .	Campo <code>responseId</code> e <code>modelVersion</code> ao nível raiz da resposta.

Tabela 2.2: Mapeamento técnico do processamento de respostas, execução e telemetria (*Responses*).

À semelhança dos pedidos, a estrutura JSON das respostas foi esquematizada para evidenciar as diferenças e semelhanças de cada resposta. A Figura 2.2 apresenta essa comparação estrutural. Os exemplos JSON completos das respostas encontram-se no Apêndice A.2.

OpenAI Response	Anthropic Response	Gemini Response
<pre>{ "id": "chatcmpl-...", "choices": [{ "index": 0, "message": { "role": "assistant", "content": "...", "tool_calls": [{ "id": "call_...", "type": "function", "function": { "name": "func", "arguments": "{ \"...\" }" } }] }, "finish_reason": "stop" }], "usage": { "prompt_tokens": 10, "completion_tokens": 20 } }</pre>	<pre>{ "id": "msg-...", "role": "assistant", "content": [{ "type": "text", "text": "..." }, { "type": "tool_use", "id": "toolu_...", "name": "func", "input": {...} }], "stop_reason": "end_turn", "usage": { "input_tokens": 10, "output_tokens": 20 } }</pre>	<pre>{ "candidates": [{ "content": { "role": "model", "parts": [{"text": "..."}, { "functionCall": { "name": "func", "args": {...} } }] }, "finishReason": "STOP" }], "usageMetadata": { "promptTokenCount": 10, "candidatesTokenCount": 20 } }</pre>

Figura 2.2: Estruturas JSON esquemáticas e simplificadas de respostas para cada fornecedor.

A comparação das respostas reforça a percepção de que as três APIs divergem significativamente na organização estrutural, apesar de exprimirem os mesmos conceitos. A interface da **OpenAI** encapsula a resposta dentro de um *array* denominado **choices**, que contém um objeto **message** [1]; a interface da **Anthropic** expõe o conteúdo diretamente na raiz através de um *array* **content** com blocos tipados [2]; e a interface da **Gemini** utiliza **candidates** com **parts** e conceitos adicionais, como **thoughtSignature** [3].

Um aspeto particularmente relevante é a representação dos argumentos em chamadas de ferramenta: a **OpenAI** serializa-os como uma *string* JSON dentro do campo **arguments**, obrigando a uma desserialização adicional [1], enquanto a **Anthropic** e a **Gemini** devolvem JSON nativo nos campos **input** [2] e **args** [3], respetivamente. A contabilização de *tokens* também difere na nomenclatura e granularidade: a API da **Gemini**, por exemplo, expõe um campo adicional **thoughtsTokenCount** que permite distinguir os *tokens* de raciocínio dos *tokens* de conteúdo efetivo [3].

2.1.3 Divergências na Padronização de Esquemas de Validação

Para além das diferenças do corpo JSON, é importante referir a divergência na forma como cada fornecedor padroniza a tipagem de dados estruturados, nomeadamente na declaração de ferramentas (*tools*) e nas saídas estruturadas (*structured outputs*).

Enquanto a **OpenAI** [24] e a **Anthropic** [25] se apoiam nativamente na norma *JSON Schema* [26] para definir propriedades e parâmetros, a API da **Gemini** adota um subconjunto da especificação *OpenAPI 3.0* [27] (através do seu objeto *Schema* [28]). Isto reforça que a construção de uma camada de abstração exige não só o mapeamento de chaves, mas também a tradução e compatibilização entre diferentes definições de esquemas.

2.1.4 Conclusão do Estudo das APIs de Inferência

A realização deste estudo envolveu dificuldades práticas que merecem ser documentadas. Para a API da **OpenAI**, o acesso direto à API oficial implica custos de utilização, pelo que os testes foram realizados utilizando a API da **Groq** [15], que oferece um plano gratuito e implementa uma interface compatível com o formato da **OpenAI** (`/v1/chat/completions`). Adicionalmente, foram executados testes complementares contra uma instância local de **Ollama** [29], que também expõe um *endpoint* compatível com o formato **OpenAI**. Para a API da **Anthropic**, a situação foi semelhante: a API oficial requer um plano de subscrição pago, pelo que os testes foram realizados utilizando o **Ollama**, que disponibiliza um *endpoint* compatível com o formato da **Anthropic** (`/v1/messages`). Embora o **Ollama** implemente corretamente as interfaces de compatibilidade para pedidos simples, de *streaming* e com parâmetros de configuração, algumas funcionalidades mais avançadas, nomeadamente o *tool calling* estruturado e a geração de blocos de raciocínio (*thinking*) apresentaram limitações quando executadas em modelos de pequena dimensão, como o `llama3.2:1b`. Nesses casos, os exemplos de resposta foram ajustados para refletir com fidelidade o comportamento documentado das APIs oficiais. A API do **Gemini** foi a única cujos testes foram executados diretamente contra a API oficial, nomeadamente através do **AI Studio** [30], uma vez que este disponibiliza um nível de acesso gratuito.

Do ponto de vista técnico, o estudo permitiu concluir que as três APIs partilham um conjunto de conceitos fundamentais, como as mensagens, papéis, ferramentas, *streaming* e contabilização de *tokens*, mas implementam-nos de formas estruturalmente diferentes. As diferenças manifestam-se na nomenclatura dos campos, na organização hierárquica do JSON, na localização dos parâmetros de configuração e nos mecanismos de ativação de funcionalidades como *streaming* e raciocínio. Contudo, apesar destas similaridades conceituais, ainda existem campos proprietários em cada API de fornecedor de inferência. Esta análise permitiu perceber que uma abstração que pretenda cobrir estes três fornecedores precisa de ir além de uma simples tradução de nomes, exigindo uma compreensão das diferenças semânticas e estruturais observadas nos pedidos e respostas reais.

2.2 Model Context Protocol (MCP)

O **Model Context Protocol (MCP)** é um protocolo aberto criado para uniformizar a forma como aplicações de Inteligência Artificial acedem a ferramentas, dados e outras fontes de contexto

[10]. Antes do surgimento do **MCP**, a integração destes recursos era normalmente realizada através de mecanismos específicos de cada aplicação ou fornecedor, resultando em soluções pouco reutilizáveis e difíceis de manter.

O protocolo define uma arquitetura cliente-servidor na qual os servidores disponibilizam capacidades que podem ser utilizadas por aplicações de IA. Estas capacidades são agrupadas em três categorias principais:

- **Tools**: operações que podem ser executadas pelo modelo, permitindo interagir com sistemas externos ou realizar ações específicas.
- **Resources**: informação disponibilizada pelos servidores para consulta, normalmente identificada através de URIs.
- **Prompts**: modelos de interação reutilizáveis que podem ser parametrizados e utilizados em diferentes cenários.

A comunicação entre clientes e servidores é realizada através de mensagens JSON-RPC e pode utilizar diferentes mecanismos de transporte, incluindo **stdio**, **HTTP**, **SSE** e **WebSocket** [31].

No modelo definido pelo protocolo, o *host* corresponde à aplicação responsável por coordenar as ligações aos servidores **MCP**. Dentro do *host*, os *clients* estabelecem ligações individuais com os servidores, que por sua vez disponibilizam as ferramentas, recursos e *prompts*. Esta separação permite que novas capacidades sejam adicionadas sem necessidade de alterar diretamente a lógica da aplicação que utiliza os modelos.

O estudo do **MCP** foi realizado em paralelo com a análise das APIs de inferência. Enquanto o objetivo dessa análise era compreender a interação com os modelos, o objetivo aqui foi perceber de que modo ferramentas e contexto externo podem ser disponibilizados de forma uniforme e independente do fornecedor do modelo.

Para complementar a análise teórica, foi desenvolvido um pequeno protótipo utilizando a biblioteca oficial `io.modelcontextprotocol:kotlin-sdk`. O protótipo teve como objetivo validar o ciclo básico de funcionamento do protocolo, incluindo a criação de um servidor, o registo de capacidades, o estabelecimento da ligação com um cliente e a troca de mensagens. Este exercício permitiu também verificar a compatibilidade da biblioteca com **Kotlin Multiplatform** [32].

O experimento realizado permitiu compreender na prática o funcionamento do protocolo e da biblioteca oficial. Foi possível validar o processo de descoberta de capacidades, a invocação de ferramentas e a troca de informação entre clientes e servidores **MCP**.

Este estudo permitiu também perceber que o acesso a ferramentas e fontes externas de contexto constitui uma preocupação distinta da comunicação com os modelos, tendo esta separação influenciado algumas decisões tomadas posteriormente na arquitetura da **OmniAI**.

Capítulo 3

Modelação do Domínio Comum

3.1 Visão Global do Domínio

No final do estudo prévio realizado no capítulo anterior, verificou-se uma acentuada fragmentação estrutural entre os principais fornecedores de Modelos de Linguagem de Grande Escala (LLMs) [13]. A ausência de uma padronização ou um protocolo comum leva à inconsistência entre as APIs da **OpenAI** [1], **Anthropic** [2] e **Gemini** [3], as quais têm campos distintos, diferentes ciclos de vida para o fluxo de dados e estruturas de objetos incompatíveis entre as várias APIs.

Para garantir a interoperabilidade, a arquitetura do **OmniAI SDK** assenta na criação de um modelo de domínio comum. A ideia foi criar um modelo de dados interoperável com os maiores fornecedores de inferência para representar pedidos, respostas e eventos dos mesmos, mas sem copiar diretamente a estrutura de nenhum deles.

Assim, o domínio funciona como um ponto intermédio estável que centraliza qualquer interação no **OmniAI SDK**. Isto significa que, independentemente de o cliente estruturar o seu pedido original no formato de um fornecedor específico (como por exemplo a **Anthropic**), esse contrato é imediatamente convertido para o domínio unificado e em seguida, para efetuar a chamada à API, o modelo comum é novamente traduzido para o formato nativo do fornecedor de destino. O mesmo processo inverso ocorre na receção da resposta, os dados que são devolvidos pela API externa são normalizados no nosso domínio comum antes de serem entregues ao cliente na estrutura esperada. Este fluxo completo de transformações está representado visualmente na Figura 3.1.




Figura 3.1: Fluxo de normalização entre contratos externos e domínio comum (**OmniAi-SDK**)

3.2 Estrutura do Domínio Comum

O domínio comum do **OmniAI SDK** que consite no conjunto de classes e relações que padroniza as interações com os diferentes fornecedores divide-se em dois blocos principais: **Request** e **Response**.

- O **Request** define a estrutura dos pedidos enviados ao modelo.
- O **Response** descreve as respostas devolvidas, quer no formato (**CommonResponse**), quer em formato incremental através de eventos (**CommonResponseEvent**).

3.2.1 CommonRequest

O **CommonRequest** é o modelo base que normaliza qualquer pedido a LLMs, garantindo um contrato único e consistente, independentemente do fornecedor. A estrutura foi desenhada para manter os elementos essenciais de geração (fornecedor, modelo e mensagens) e, ao mesmo tempo, permitir extensões controladas via configuração e opções específicas do *provider*. Como se observa na Figura 3.2, o **CommonRequest** agrega diretamente o **provider**, o **model** e a lista de **messages**, que representam o histórico conversacional. Cada **CommonRequestMessage** contém o papel (**CommonRole**) e o conteúdo em partes (**RequestContentPart**), permitindo combinar texto, JSON ou chamadas a ferramentas. A configuração de geração é isolada em **CommonGenerationConfig**, enquanto as ferramentas disponíveis são descritas por **CommonTool** e controladas por **ToolChoice**. Por fim, **SystemPrompt** e **providerOptions** suportam personalizações globais e específicas do fornecedor, mantendo o core estável e extensível.




Figura 3.2: Estrutura de classes do **CommonRequest**.

Para sistematizar a estrutura apresentada na Figura 3.2, a Tabela 3.1 agrega todos os parâmetros relevantes do domínio de *Request*, incluindo o objeto principal e os tipos diretamente associados. O objetivo é apresentar o significado funcional de cada campo no fluxo de construção do pedido.

Elemento	Campo	Tipo	Descrição
CommonRequest	<i>provider</i>	Provider	Fornecedor alvo da chamada.
CommonRequest	model	String	Identificador do modelo a utilizar.
CommonRequest	messages	List<Common-RequestMessage>	Histórico de mensagens enviado ao modelo.
CommonRequest	systemPrompt	SystemPrompt?	Prompt de sistema global (opcional).
CommonRequest	config	Common-GenerationConfig?	Parâmetros de geração (opcional).
CommonRequest	tools	List<CommonTool>	Ferramentas disponíveis para chamadas de função.
CommonRequest	toolChoice	ToolChoice?	Política de seleção de ferramentas.
CommonRequest	jsonResponse	Boolean	Indica se a resposta deve ser forçada a JSON.
CommonRequest	providerOptions	TypedMap	Opções específicas do fornecedor.
CommonRequest-Message	role	CommonRole	Papel da mensagem (SYSTEM, USER, ASSISTANT, TOOL).
CommonRequest-Message	content	List<Request-ContentPart>	Conteúdo segmentado da mensagem.
SystemPrompt	text	String	Conteúdo do prompt de sistema.
Common-GenerationConfig	temperature	Double?	Grau de aleatoriedade da geração.
Common-GenerationConfig	maxTokens	Int?	Limite máximo de <i>tokens</i> de saída.
Common-GenerationConfig	topP	Double?	Probabilidade cumulativa.
Common-GenerationConfig	stopSequences	List<String>?	Sequências que interrompem a geração.
CommonTool	name	String	Nome da ferramenta.
CommonTool	description	String	Descrição funcional da ferramenta.
CommonTool	parametersSchema	JsonObjectMap	Esquema JSON dos parâmetros.
ToolChoice	Auto / None / Required / Specific	–	Estratégia de uso de ferramentas (auto, nenhuma, obrigatório ou lista específica).
ToolChoiceAuto	–	–	Subtipo sem campos (seleção automática).
ToolChoiceNone	–	–	Subtipo sem campos (sem ferramentas).
ToolChoiceRequired	–	–	Subtipo sem campos (uso obrigatório).
ToolChoiceSpecific	toolNames	List<String>	Lista de ferramentas permitidas.
Provider	value	String	Identificador textual do fornecedor.
TypedMap	data	Map<String, Any?>	Mapa genérico de opções específicas do fornecedor.
RequestContentPart	TextPart	text: String	Conteúdo textual.
RequestContentPart	JsonPart	json: JsonValue	Conteúdo JSON estruturado.
RequestContentPart	ToolCallPart	toolCallId, functionName, argumentsJson	Chamada a ferramenta com argumentos.
RequestContentPart	ToolResultPart	toolCallId, content	Resultado de execução de ferramenta.

Tabela 3.1: Parâmetros do domínio de *Request*.

3.2.2 CommonResponse e CommonResponseEvent

O `CommonResponse` é o modelo base que normaliza as respostas devolvidas pelos diferentes fornecedores, garantindo um contrato único e consistente para o cliente. A estrutura foi desenhada para representar o resultado final da geração, mantendo as escolhas (`CommonChoice`) com o respetivo índice e a razão de término (`FinishReason`). Cada escolha contém uma mensagem (`CommonResponseMessage`) com o papel (`CommonRole`) e o conteúdo em partes (`ResponseContentPart`), permitindo combinar texto, JSON, chamadas a ferramentas ou recusas. A informação de uso (`CommonUsage`) isola o consumo de *tokens* e facilita métricas e contabilização. Por fim, `providerOptions` preserva metadados específicos do fornecedor, mantendo o núcleo do domínio estável e extensível.




Figura 3.3: Estrutura de classes do `CommonResponse`.

A Tabela 3.2 reúne os campos do domínio de *Response*, incluindo o objeto base, as escolhas e os eventos de *streaming*.

Elemento	Campo	Tipo	Descrição
CommonResponse	<i>provider</i>	Provider	Fornecedor que produziu a resposta.
CommonResponse	id	String	Identificador do pedido/execução.
CommonResponse	model	String	Identificador do modelo utilizado.
CommonResponse	choices	List<CommonChoice>	Lista de escolhas geradas.
CommonResponse	usage	CommonUsage?	Contabilização de <i>tokens</i> (opcional).
CommonResponse	providerOptions	Map<String, Any?>	Metadados específicos do fornecedor.
CommonChoice	index	Int	Índice da escolha.
CommonChoice	message	CommonResponseMessage	Mensagem com papel e conteúdo.
CommonChoice	finishReason	FinishReason?	Razão de término da escolha (opcional).
CommonResponseMessage	role	CommonRole	Papel da mensagem.
CommonResponseMessage	content	List<ResponseContentPart>	Conteúdo segmentado da resposta.
CommonUsage	inputTokens	Int?	Tokens de entrada.
CommonUsage	outputTokens	Int?	Tokens de saída.
CommonUsage	totalTokens	Int?	Total de <i>tokens</i> .
FinishReason	–	STOP / LENGTH / TOOL_CALL / CONTENT_FILTER / OTHER	Motivo de conclusão da geração.
ResponseContentPart	TextPart	text: String	Segmento textual.
ResponseContentPart	JsonPart	json: JsonValue	Segmento JSON estruturado.
ResponseContentPart	ToolCallPart	toolCallId, functionName, argumentsJson	Chamada a ferramenta.
ResponseContentPart	RefusalPart	reason: String	Recusa do modelo com justificção.

Tabela 3.2: Parâmetros do domínio de *Response* (CommonResponse).

O **CommonResponseEvent** complementa o **CommonResponse** ao representar respostas em *streaming* como uma sequência ordenada de eventos. Esta abordagem permite construir a saída de forma incremental: primeiro sinaliza o início da resposta, depois o arranque de cada escolha, segue com deltas de texto ou de argumentos de ferramentas e, por fim, reporta o fecho da escolha, o uso de *tokens* e a conclusão (ou erro) do *stream*. Cada evento partilha um conjunto mínimo de metadados (fornecedor, identificador, modelo e sequência) que asseguram consistência e reordenação determinística.

Elemento	Campo	Tipo	Descrição
CommonResponse Event	<i>provider</i>	Provider	Fornecedor associado ao evento.
CommonResponse Event	id	String	Identificador do pedido/execução.
CommonResponse Event	model	Model	Modelo utilizado no evento.
CommonResponse Event	sequence	Long	Ordem do evento no <i>stream</i> .
CommonResponse Event	<i>provider</i> EventType	String?	Tipo bruto do evento do fornecedor (opcional).
ResponseStarted	–	–	Início do <i>streaming</i> da resposta.
ChoiceStarted	choiceIndex	Int	Índice da escolha iniciada.
ChoiceStarted	role	CommonRole?	Papel associado à escolha (opcional).
TextDeltaEvent	choiceIndex	Int	Índice da escolha que recebe o delta.
TextDeltaEvent	text	String	Fragmento incremental de texto.
ToolCall StartedEvent	choiceIndex	Int	Índice da escolha.
ToolCall StartedEvent	toolCallIndex	Int	Índice da chamada a ferramenta.
ToolCall StartedEvent	toolCallId	String	Identificador da chamada a ferramenta.
ToolCall StartedEvent	functionName	String	Nome da função invocada.
ToolCallArguments DeltaEvent	choiceIndex	Int	Índice da escolha.
ToolCallArguments DeltaEvent	toolCallIndex	Int	Índice da chamada a ferramenta.
ToolCallArguments DeltaEvent	arguments Fragment	String	Fragmento incremental de argumentos.
ChoiceFinished	choiceIndex	Int	Índice da escolha terminada.
ChoiceFinished	finishReason	FinishReason?	Razão de término (opcional).
UsageReported	usage	CommonUsage	Contabilização de <i>tokens</i> reportada.
ResponseCompleted	–	–	Conclusão do <i>streaming</i> da resposta.
ResponseErrored	message	String	Mensagem de erro.
ResponseErrored	retryable	Boolean	Indica se o erro é recuperável.

Tabela 3.3: Parâmetros do domínio de *Response* (CommonResponseEvent).

3.3 TypedMap e Extensibilidade do Domínio

Nem todos os dados relevantes pertencem ao modelo mínimo de inferência. Algumas informações são específicas do fornecedor, como parâmetros avançados do **Gemini** e outras pertencem ao contexto operacional, como metadados de autenticação, IP do cliente, cabeçalhos **HTTP** ou atributos necessários para observabilidade e autorização. Para estes casos, o **OmniAI SDK** introduz a estrutura **TypedMap**.

O **TypedMap** funciona como um mapa de atributos tipado por chave. Cada **AttributeKey<T>** associa um nome lógico a um tipo esperado, permitindo guardar e recuperar valores sem depender de conversões frágeis de strings. Esta abordagem é mais segura do que um **Map<String, Any?>**

puro, porque cada chave transporta também a expectativa de tipo. Ao mesmo tempo, é mais flexível do que adicionar campos ao domínio sempre que surge uma necessidade nova.




Figura 3.4: Utilização da `TypedMap` para transportar atributos extensíveis

No domínio de inferência, a `TypedMap` aparece em `providerOptions`, permitindo preservar dados que não pertencem ao subconjunto comum mas não devem ser perdidos durante a tradução. Fora da inferência estrita, a mesma estrutura permite transportar metadados entre componentes sem criar dependências diretas entre eles. Esta característica é útil para a evolução futura do **OmniAI SDK**, porque permite que mecanismos ,como autorização, observabilidade ou políticas de execução, usem atributos adicionais sem forçar alterações constantes nas classes centrais do domínio.

Capítulo 4

Arquitetura e Desenho do Sistema

A arquitetura de alto nível (*top-level*) apresentada na Figura 4.1 posiciona o **OmniAI SDK** como o principal resultado deste projeto. Em vez de constituir uma aplicação final isolada, o **OmniAI SDK** fornece um conjunto de abstrações, componentes e mecanismos reutilizáveis que permitem construir soluções de integração com múltiplos fornecedores de modelos de linguagem de forma consistente. Entre estes componentes encontram-se o domínio comum de pedidos e respostas, os contratos normalizados, os adaptadores responsáveis pela tradução entre o modelo interno e as APIs externas, o *pipeline* de interceptação para funcionalidades transversais e uma DSL de configuração que simplifica a composição do sistema.

A utilização do **OmniAI SDK** traduz-se, na prática, na criação de uma **OmniAI Gateway** adaptada às necessidades de cada utilizador. A **Gateway** funciona como uma camada de acesso unificada sobre diferentes fornecedores de modelos, abstraindo as diferenças existentes entre APIs e disponibilizando uma interface homogênea para clientes e aplicações consumidoras. Desta forma, aspetos relacionados com autenticação, observabilidade, resiliência, encaminhamento de pedidos ou integração com ferramentas externas podem ser configurados ao nível da **Gateway** sem impactar a lógica das aplicações que a utilizam.

Para validar a arquitetura proposta e demonstrar a aplicabilidade do nosso *Software Development Kit* num cenário real, foi desenvolvida uma instância concreta da **OmniAI Gateway** como Prova de Conceito (*Proof of Concept* – PoC). Esta instância é construída integralmente através dos mecanismos disponibilizados pelo **OmniAI SDK**, recorrendo a configurações declarativas para definir fornecedores, modelos, políticas de autenticação, métricas e restantes componentes da infraestrutura. Durante o arranque da aplicação, estas configurações são utilizadas para compor dinamicamente os adaptadores, a *pipeline* de processamento e os conectores **HTTP** baseados em **Ktor** [33], expondo posteriormente um conjunto de *endpoints* compatíveis com os contratos normalizados definidos pelo domínio comum.

Esta separação entre **OmniAI SDK** e **OmniAI Gateway** constitui uma das principais decisões arquiteturais do projeto. A biblioteca concentra toda a lógica reutilizável e independente do contexto de execução, enquanto cada **Gateway** representa uma instanciação específica dessa infraestrutura, podendo ser configurada para diferentes fornecedores, requisitos operacionais ou cenários de utilização sem necessidade de alterar os componentes centrais do sistema.




Figura 4.1: Arquitetura Top Level: O **OmniAI SDK** utilizado para instanciar uma **OmniAI Gateway**, abstraindo integrações externas padronizadas.




Figura 4.2: Visão da integração entre **Ktor**, *inbounds*, *pipeline*, *interceptors*, *outbounds* e **HTTP client** no **OmniAI SDK**

A Figura 4.1 mostra que a **OmniAI Gateway** não contém a lógica essencial de tradução, despacho ou resiliência. Essa lógica pertence ao **OmniAI SDK** e é apenas instanciada pela aplicação final. A Figura 4.2 aproxima a visão interna isto é um conector **HTTP** recebe o corpo do pedido, converte-o para um DTO de contrato, invoca um *inbound adapter*, e este chama um **DispatcherPort**. A partir desse ponto, a execução pode seguir por um *dispatcher* direto ou por

um *dispatcher* apoiado numa *pipeline*. No final, um *outbound adapter* traduz o pedido comum para o contrato do fornecedor e utiliza um cliente **HTTP** abstrato para executar a chamada real.

Esta organização permite que aplicações já compatíveis com APIs existentes possam ser integradas com esforço reduzido. Por exemplo, uma aplicação preparada para a API **Anthropic** pode alterar o seu `baseURL` para apontar para a **OmniAI Gateway**, mantendo o contrato esperado pelo cliente. O mesmo princípio aplica-se a clientes compatíveis com a API de inferência da **OpenAI** e API de inferência do **Gemini**.

A arquitetura foi também pensada para escalamento horizontal: o **OmniAI SDK** evita estado global obrigatório, concentra estado transitório no contexto do pedido e define portas para substituir *stores* em memória por *backends* partilhados quando a **Gateway** é executada em múltiplas instâncias.

4.1 Arquitetura Hexagonal (Ports & Adapters)

A Arquitetura Hexagonal, também conhecida como padrão de Portas e Adaptadores, foi escolhida neste projeto para garantir que a lógica principal do sistema permaneça independente de detalhes técnicos e de integrações externas. Em vez de o *core* da aplicação depender diretamente de bibliotecas, protocolos ou APIs específicas, toda a comunicação com o exterior acontece através de interfaces bem definidas, enquanto os adaptadores tratam das implementações concretas [7, 34, 35].

Esta separação torna-se especialmente importante no contexto de uma *Gateway* de Inteligência Artificial, uma vez que o sistema atua como ponto central de comunicação entre clientes **HTTP**, fornecedores de inferência, mecanismos de autenticação e serviços de observabilidade. Sem um isolamento arquitetural claro, a lógica de domínio acabaria inevitavelmente dependente de *SDKs* externos, formatos proprietários e detalhes específicos de integração de cada fornecedor.

Ao adotar esta abordagem, foi possível manter o *core* do **OmniAI SDK** focado apenas nas responsabilidades centrais de normalização, abstração e coordenação. Assim, funcionalidades como chamadas de rede, serialização de dados ou integração com APIs externas ficam confinadas aos adaptadores. Isto permite que novos fornecedores de IA, novos mecanismos de autenticação e outros mecanismos sejam adicionados com alterações mínimas na lógica principal da aplicação.

Durante o desenho da solução, foram analisadas outras abordagens arquiteturais para avaliar qual delas se ajustava melhor aos requisitos do projeto. Uma das alternativas consideradas foi a arquitetura tradicional em camadas. Apesar de ser uma solução mais simples numa fase inicial, este modelo tende a perder clareza estrutural à medida que o sistema cresce. Com o tempo, torna-se comum encontrar regras de negócio misturadas com lógica de transporte, chamadas **HTTP** e tratamento de contratos externos, aumentando o acoplamento e dificultando a manutenção [36].

Neste contexto, a Arquitetura Hexagonal revelou-se a solução mais adequada para os objetivos do projeto. A abordagem oferece modularidade, isolamento e flexibilidade suficientes para lidar com as diferentes políticas transversais exigidas por uma *Gateway* de Inteligência Artificial, como autenticação, resiliência, observabilidade e roteamento de pedidos, mantendo ao mesmo tempo uma estrutura organizada e simples de evoluir [18–20]. Além disso, esta organização ar-

quitetural facilita a introdução de novos fornecedores e novas funcionalidades sem comprometer a estabilidade do núcleo da aplicação.

4.1.1 Contracts

Os módulos `contracts:openai`, `contracts:anthropic` e `contracts:gemin`i modelam os formatos de pedido, resposta e eventos de cada fornecedor. Estes contratos são DTOs no sentido em que representam dados transportados na fronteira do sistema, mas não são apenas DTOs genéricos. São chamados *contracts* porque codificam uma compatibilidade externa concreta: nomes de campos, estruturas JSON, eventos de *streaming*, campos opcionais, formatos de erro e convenções específicas de cada API.

Esta distinção é importante. Um DTO interno poderia ser livremente alterado sem impacto externo um contrato compatível com **OpenAI**, **Anthropic** ou **Gemini** precisa de respeitar o formato que clientes e fornecedores esperam. Ao isolar estes contratos em módulos próprios, o **OmniAI SDK** evita que detalhes como `tool_calls`, `content_block_delta` ou `functionDeclarations` se espalhem pelo domínio comum.

4.1.2 Inbounds

Os *inbound adapters* recebem pedidos no formato do cliente e traduzem-nos para `CommonRequest`. Cada *inbound* implementa a porta `InboundPort` e recebe um `DispatcherPort`, não uma implementação concreta de *pipeline* ou de fornecedor. Além disso, cada *inbound* usa uma implementação de `InboundTranslator`, responsável por converter o objeto de entrada para domínio e por converter a resposta comum de volta para o contrato do cliente.

Esta decisão evita que o *inbound* exponha diretamente uma Web API. O **OmniAI SDK** fornece *adapters* que trabalham sobre objetos de transferência, e a exposição **HTTP** fica noutra *adapter*, como o `gateway-ktor-server` (detalhado na Secção 5.5). Assim, um servidor **Ktor**, uma função *serverless*, um *handler* Express ou outro mecanismo de entrada podem chamar o mesmo *inbound* desde que consigam construir o DTO esperado. Esta separação reduz a dependência do domínio e dos *inbounds* face a bibliotecas **HTTP** externas.

4.1.3 Outbounds

Os *outbound adapters* fazem o caminho inverso: recebem um `CommonRequest`, traduzem-no para o contrato do fornecedor real e executam a chamada externa. Cada *outbound* implementa `OutboundPort`, identifica `provider`, `model` e `key`, e delega a tradução num `OutboundTranslator`. A implementação atual inclui *outbounds* para **OpenAI**, **Anthropic** e **Gemini**.

Ao contrário dos *inbounds*, os *outbounds* precisam de comunicar com serviços externos. Por isso, recebem uma implementação de `HttpClient`, a porta de transporte **HTTP** descrita na Secção 4.1.4, que abstrai por completo o mecanismo de rede utilizado. Esta inversão de dependência é o que permite testar *adapters* sem depender de chamadas reais e evoluir o ambiente de execução sem reescrever o domínio.

4.1.4 `HttpTransportClient`

A interface `HttpTransportClient`, definida no módulo `core`, representa a porta de saída responsável por toda a comunicação **HTTP** do nosso **SDK** com os fornecedores externos. Esta abstração isola completamente os *outbound adapters* de qualquer biblioteca ou mecanismo concreto de rede, seguindo o princípio de inversão de dependência que caracteriza a Arquitetura Hexagonal.

A interface expõe três operações distintas. A operação `execute` é utilizada para pedidos síncronos: recebe uma configuração tipificada de pedido (`RequestConfig`) e um serializador, executa a chamada **HTTP** e devolve um `HttpCallResult`. A operação `listen` destina-se a respostas em *streaming* baseadas em *Server-Sent Events* (**SSE**) com um único tipo de evento, devolvendo um `Flow` de resultados. A operação `listenMany` generaliza o modelo de **SSE** para cenários com múltiplos tipos de eventos, selecionando o serializador adequado com base no campo `event` de cada mensagem.

O resultado de qualquer chamada **HTTP** é representado pela classe selada `HttpCallResult`, parametrizada pelo tipo da resposta esperada. Esta classe cobre os seguintes casos: `Success`, que encapsula os dados desserializados; `ApiError`, que retém o código de estado **HTTP** e o corpo da resposta de erro; `NetworkError`, originado por falhas de conectividade; `SerializationError`, resultante de respostas com formato inesperado; e `UnknownError`, para situações não classificadas. Todos os casos carregam um `TypedMap` de metadados, que permite propagar cabeçalhos de resposta e outras informações contextuais para os adaptadores e interceptores de forma estruturada.

A implementação concreta desta interface é descrita na Secção 5.6.

4.1.5 `Dispatcher`

O `DispatcherPort` é a porta chamada pelos *inbounds* para executar um `CommonRequest`. A sua responsabilidade não é, por si só, conter inteligência de roteamento; é despachar o pedido para uma estratégia de execução. No **OmniAI SDK** é fornecida uma implementação simples, criada por `routingDispatcherFactory`, que procura o *outbound* cujo `provider` e `model` correspondem aos campos do pedido e envia a chamada para esse *adapter*.

Como se trata de uma interface, a arquitetura permite outras implementações com objetivos diferentes. Um consumidor do **SDK** pode fornecer um *dispatcher* direto, um *dispatcher* com seleção por custo, um *dispatcher* que consulta políticas externas ou um *dispatcher* que aplica regras mais complexas. A *pipeline* fornecida pelo **SDK** é ela própria encaixada através de um *adapter*, `PipelineBackedDispatcher`, preservando a ideia de que os *inbounds* dependem apenas de `DispatcherPort`.

4.2 Organização do SDK

O **SDK** está organizado como um projeto **Gradle** multi-módulo. Os módulos principais incluem `core`, `contracts`, `inbound`, `outbound`, `interceptors`, `mcp-broker`, `dispatcher`, `gateway-client`, `gateway-ktor-server` e `contracts:ktor-http`. Esta divisão permite evoluir cada área com responsabilidades claras: domínio e portas em `core`, contratos externos em `contracts`, *adapters*

de entrada e saída em módulos próprios, preocupações transversais em `interceptors`, montagem declarativa em `gateway-client` e exposição **HTTP/Ktor** em `gateway-ktor-server`.

O módulo `contracts:ktor-http` fornece a abstração de transporte `HttpTransportClient` e a implementação `KtorHttpTransportClient`. Esta camada encapsula chamadas **HTTP**, **SSE**, serialização, metadados de resposta, erros de rede e erros de parsing. Ao colocá-la atrás de uma interface, os *outbounds* não ficam presos a uma implementação específica de cliente **HTTP**.

O módulo `gateway-client` disponibiliza uma DSL para montar uma **Gateway**. A aplicação consumidora pode declarar *outbounds*, *interceptors*, autenticação, autorização e modo de execução. A DSL permite escolher entre `useNativePipeline`, que monta a *pipeline* e o *dispatcher* padrão, e `useCustomDispatcher`, que permite substituir totalmente a estratégia de execução. Esta flexibilidade é essencial para um **SDK**: o POC usa a montagem nativa, mas outro consumidor pode querer um *dispatcher* próprio.

A instância da **OmniAI Gateway** desenvolvida no âmbito deste projeto foi concebida exclusivamente como uma Prova de Conceito (*Proof of Concept* - PoC), com o objetivo de validar o processo de instanciação e configuração disponibilizado pelo **SDK**. Durante o desenvolvimento, a solução foi estruturada recorrendo à funcionalidade de *composite build* do **Gradle**, através da diretiva `includeBuild("../OmniAi-SDK")` [37].

Esta decisão não pretende representar o modelo final de utilização da plataforma em ambiente de produção. A sua adoção teve um propósito essencialmente prático, permitindo desenvolver e compilar simultaneamente o **SDK** e a **Gateway** instanciada sem depender de ciclos constantes de publicação de versões intermédias da biblioteca. Desta forma, qualquer alteração efetuada no núcleo do **SDK** podia ser imediatamente refletida e validada no Proof of Concept criado, reduzindo significativamente o tempo necessário para testar novas funcionalidades, ajustes arquiteturais ou alterações ao *pipeline* interno da **Gateway**.

Sem esta abordagem, o processo de desenvolvimento tornar-se-ia substancialmente mais lento, uma vez que cada alteração implicaria publicar uma nova versão da biblioteca, atualizar dependências no projeto consumidor e recompilar novamente toda a aplicação. A utilização de *composite builds* permitiu assim criar um ciclo de desenvolvimento mais rápido e iterativo, particularmente importante numa fase de exploração arquitetural e validação técnica do **SDK**.

Num cenário de adoção real, a expectativa arquitetural é diferente. O **SDK** deverá ser consumido como uma dependência externa devidamente versionada, distribuída através de plataformas de gestão de dependências, como **Maven** no ecossistema **JVM** ou **NPM** em ambientes **Node.js** e **TypeScript**. Desta forma, diferentes equipas poderão instanciar e integrar a sua própria **Gateway** de forma independente, mantendo um processo de versionamento e distribuição consistente com as práticas tradicionais de engenharia de software.

Capítulo 5

Implementação e Evolução Técnica

5.1 Stack Tecnológica e Metodologias

O **OmniAI SDK** foi desenvolvido em **Kotlin Multiplatform** [6] com *targets* **JVM** e **JavaScript/Node.js**. A escolha de **KMP** permite partilhar o domínio, os contratos, as portas, os *adapters* principais e parte da lógica geral entre plataformas, mantendo implementações específicas quando o ambiente o exige [23]. A serialização dos contratos é baseada em **Kotlinx Serialization** [38], o que facilita a definição explícita dos modelos JSON que foram estudados anteriormente.

O *core* do **OmniAI SDK** é estritamente agnóstico em relação a *frameworks* web e mecanismos de transporte **HTTP**. Contudo, para fornecer uma solução imediatamente utilizável, o projeto inclui módulos oficiais de integração baseados na *framework* **Ktor** [33]. Estes módulos opcionais oferecem implementações de referência tanto para a execução de pedidos aos fornecedores (*client-side*) como para a exposição das rotas da **Gateway** (*server-side*). A **OmniAI Gateway** instanciada como Prova de Conceito (PoC) tira partido destas implementações prontas a usar. No entanto, a adoção do **OmniAI SDK** não obriga ao uso do **Ktor** a arquitetura garante que qualquer o utilizador possa descartar estes módulos e implementar os adaptadores de rede utilizando a tecnologia da sua preferência, como o Spring por exemplo, entre outros.

As ferramentas de desenvolvimento incluíram Git, IntelliJ IDEA, o cliente **HTTP** do IDE para pedidos REST, **Docker** Compose para **Logto** [39], **PostgreSQL** [40], **OpenTelemetry Collector** [41], **Prometheus** [42] e **Grafana** [43], além de clientes reais como **Claude Code** e SDKs oficiais dos fornecedores. Também foram usados assistentes de apoio, como **Gemini** no *browser* e agentes de programação como o Antigravity e Codex, para pesquisa, comparação de documentação e aceleração de tarefas, mantendo a validação no código, nos testes e nos cenários executados. Foi criada uma *pipeline* de **Continuous Integration** (CI) [44] existente executa `./gradlew clean build` como passo evolutivo, está prevista a criação de uma *pipeline* de **Continuous Deployment** (CD) para publicar as versões do nosso *Software Development Kit*, o **OmniAI SDK** em Maven e NPM.

5.2 A Primeira Iteração da Gateway

A primeira iteração do projeto consistiu numa **Gateway HTTP** construída diretamente, responsável por receber pedidos de clientes e encaminhá-los para fornecedores de inferência. Esta fase foi útil para validar rapidamente a viabilidade da solução, testar pedidos reais e compreender diferenças práticas entre as diferentes API's dos fornecedores, neste caso da **OpenAI** [1], **Anthropic** [2] e **Gemini** [3].

À medida que o sistema cresceu, essa abordagem revelou acoplamento excessivo. A tradução entre contratos, a configuração dos fornecedores, a autenticação, o tratamento de erros e o encaminhamento de pedidos começaram a concentrar-se na própria aplicação. Cada novo fornecedor ou preocupação exigia alterações no mesmo conjunto de componentes, tornando o código difícil de evoluir e de se testar.

A reorganização da arquitetura separou o produto principal, o **OmniAI SDK**, de uma aplicação final denominada **OmniAI Gateway**. O **OmniAI SDK** passou a concentrar toda a lógica e abstrações reutilizáveis do domínio, incluindo contratos, portas e adaptadores (*Ports & Adapters*), o sistema de *dispatching*, a *pipeline* de execução, *interceptors*, DSLs de configuração e abstrações **HTTP** multiplataforma. Desta forma, o **SDK** fornece toda a infraestrutura necessária para que qualquer utilizador consiga instanciar e configurar a sua própria **OmniAI Gateway**, adaptada ao seu contexto e necessidades. A **OmniAI Gateway** representa, assim, uma aplicação concreta construída sobre o **OmniAI SDK**. No contexto deste projeto, foi desenvolvida uma **OmniAI Gateway** responsável por carregar configurações, instanciar os componentes necessários, instalar os conectores **Ktor** e expor *endpoints HTTP*.

Esta aplicação tem como objetivo validar a arquitetura proposta e demonstrar que o **OmniAI SDK** permite construir *gateways* funcionais, extensíveis e desacopladas dos diferentes fornecedores de modelos de IA. Assim, a **OmniAI Gateway** desenvolvida neste projeto atua como uma *Proof of Concept* da abordagem arquitetural definida, servindo como exemplo prático da utilização do **SDK**.

Esta separação também influenciou o desenho da arquitetura para suportar escalamento horizontal. O **OmniAI SDK** foi projetado para manter o estado associado aos pedidos apenas em estruturas transitórias, como **GatewayContext** e **TypedMap**, expondo portas explícitas para componentes que necessitam de estado partilhado, como *caches*, *rate limiting*, *circuit breakers*, autenticação e observabilidade.

Esta abordagem permite que uma instanciação simples de uma **OmniAI Gateway** utilize implementações em memória, reduzindo a complexidade inicial de configuração e execução. No entanto, em cenários de escalamento horizontal, esses mesmos mecanismos podem ser substituídos por sistemas distribuídos e partilhados, sem necessidade de alterações nos *inbounds*, *outbounds* ou contratos expostos pelo **SDK**.

Desta forma, o **OmniAI SDK** desacopla a lógica funcional da infraestrutura de persistência e sincronização, permitindo que diferentes implementações da **OmniAI Gateway** evoluam de ambientes locais e monolíticos para arquiteturas distribuídas de forma transparente.

5.3 Decisões de Desenho e Alternativas Descartadas

A análise de *trade-offs* partiu de três critérios principais: preservar a estabilidade da versão demonstrável, manter o **OmniAI SDK** reutilizável e extensível independentemente da aplicação final e evitar que funcionalidades experimentais introduzissem acoplamento excessivo no domínio comum.

Neste contexto, importa recordar que a **OmniAI Gateway** apresentada neste projeto corresponde apenas a uma instanciação concreta construída sobre o **OmniAI SDK**. Assim, várias decisões arquiteturais foram tomadas não apenas a pensar na *Proof of Concept*, mas sobretudo na preservação do nosso **SDK** enquanto infraestrutura reutilizável para futuras *gateways*, integrações e ambientes de execução.

As decisões seguintes não representam funcionalidades abandonadas, mas sim escolhas conscientes de âmbito para garantir que a primeira versão permanecesse estável, testável e arquiteturalmente coerente:

- **Geração de Bridges com KSP (Kotlin Symbol Processing):** Foi ponderada a utilização de KSP para gerar automaticamente *bridges* entre **Kotlin** e **TypeScript/Node.js**. Embora esta abordagem pudesse reduzir código manual na integração multiplataforma, implicaria lidar com configuração adicional, compatibilidade entre *targets* e diversos casos limite de tipagem entre **Kotlin** e **JavaScript**. Optou-se por uma fachada baseada em `@JsExport`, suficientemente controlada para expor o *target JavaScript* sem introduzir complexidade excessiva ou comprometer o prazo do projeto.
- **Injeção Automática de Ferramentas via SSE:** Também foi avaliada a possibilidade de a **Gateway** intercetar automaticamente *tool calls* durante *streams*, executar ferramentas e reinjetar os resultados no fluxo **SSE** de forma transparente para o cliente. Apesar de tecnicamente viável, esta funcionalidade exigiria mecanismos adicionais de gestão de estado conversacional, suspensão e retoma de streams, coordenação concorrente e normalização de diferenças entre fornecedores que emitem eventos distintos. A capacidade ficou identificada como evolução futura, mantendo a primeira versão focada nos elementos considerados essenciais: contratos comuns, *adapters*, *pipeline* de *interceptors*, segurança, observabilidade e resiliência.

5.4 Evolução Arquitetural: De *Inference Service* a *Dispatcher*

A primeira iteração da arquitetura concentrava comunicação, tradução de contratos e roteamento num componente designado por **InferenceService**. Embora esta abordagem tenha sido eficaz durante a fase inicial de desenvolvimento e prototipagem, rapidamente começou a aproximar-se de um *God Object*: cada novo fornecedor, métrica, regra de segurança ou política de erro aumentava progressivamente a responsabilidade do mesmo serviço.

O problema principal não era apenas o crescimento do componente, mas sobretudo a direção das dependências. Ao conhecer diretamente contratos **HTTP**, clientes externos, regras de seleção de fornecedor e políticas transversais, o serviço tornava-se o ponto central de acoplamento da arquitetura. Qualquer alteração numa dessas áreas propagaria impacto para o core do sistema,

dificultando testes unitários, aumentando o custo de introdução de novos *adapters* e reduzindo significativamente o valor do **SDK** enquanto fundação reutilizável para diferentes *gateways* e cenários de execução.

A refatorização substituiu esse modelo por um contrato pequeno e explícito: o **DispatcherPort**. A responsabilidade do *dispatcher* passou a ser exclusivamente receber um **CommonRequest** e delegar a execução para uma estratégia de despacho. A implementação padrão fornecida pelo **SDK**, criada através de **routingDispatcherFactory**, realiza um roteamento simples baseado no fornecedor e no modelo presentes no pedido. Contudo, por se tratar apenas de uma interface, o **SDK** não impõe esta estratégia: qualquer consumidor pode substituir o *dispatcher* por outra implementação sem necessidade de alterar *inbounds*, contratos ou *adapters* existentes.

Esta alteração teve impacto direto na modularidade da arquitetura. Os *inbounds* passaram a depender apenas da porta **DispatcherPort**; os *outbounds* ficaram responsáveis exclusivamente pela tradução de contratos e comunicação externa; e as preocupações transversais foram deslocadas para a *pipeline* de *interceptors*. Como consequência, a **OmniAiGateway** deixou de representar uma implementação rigidamente acoplada à infraestrutura interna e passou a funcionar como uma composição configurável construída sobre o **OmniAI SDK**.

Na prática, esta separação permitiu preservar o **SDK** como uma fundação independente do *Proof of Concept*, reutilizável na construção de outras *gateways*, runtimes ou integrações futuras. A **OmniAiGateway** desenvolvida neste projeto representa, assim, apenas uma configuração concreta dessa infraestrutura arquitetural, utilizada para validar a abordagem proposta e demonstrar a viabilidade do modelo definido.

5.5 Implementação da Camada HTTP: gateway-ktor-server

A camada de exposição **HTTP** da **Gateway** é implementada no módulo **gateway-ktor-server**. Este módulo estabelece a ponte entre o servidor web (**Ktor**) e os *inbound adapters* do domínio, garantindo que o núcleo do sistema permanece agnóstico em relação à tecnologia de transporte de entrada.

A implementação baseia-se num padrão de conectores (**InboundConnector**) que registra rotas específicas para cada contrato suportado. O módulo expõe três funções de extensão sobre a interface de encaminhamento (**Route**) do **Ktor**:

Conector Ktor	Caminho (Path) Predefinido	DTOs de Contrato (Pedido / Resposta)
<code>openAiConnector()</code>	<code>/v1/chat/completions</code>	<code>OpenAiChatCompletionsRequest</code> / <code>OpenAiChatCompletionsResponse</code>
<code>anthropicConnector()</code>	<code>/v1/messages</code>	<code>AnthropicMessagesRequest</code> / <code>AnthropicMessageResponse</code>
<code>geminiConnector()</code>	<code>/v1beta/models/{model}:generateContent</code>	<code>GeminiGenerateContentRequest</code> / <code>GeminiGenerateContentResponse</code>

Tabela 5.1: Conectores **HTTP** disponibilizados pela **Gateway Ktor**

A ligação entre a rota **HTTP** e a porta de entrada opera num ciclo de duas fases. Numa

primeira fase, as rotas são registadas e aguardam a injeção da dependência. Quando o servidor é iniciado, o *adapter* concreto (por exemplo, `OpenAiInboundAdapter`) é injetado no conector através da função `connect()`.

O fluxo de processamento de um pedido **HTTP** obedece sempre à mesma sequência:

1. **Desserialização:** O corpo do pedido **HTTP** é convertido para o DTO do contrato correspondente (e.g., `OpenAiChatCompletionsRequest`), devolvendo um erro 400 `Bad Request` em caso de falha sintática.
2. **Extração de Metadados:** Atributos essenciais do protocolo **HTTP** são extraídos e propagados para a `TypedMap` do contexto interno. A configuração `defaultKtorRequestMetadataBinder` processa o cabeçalho `Authorization` (removendo o prefixo `Bearer`), resolve o endereço IP do cliente (verificando `X-Forwarded-For` e `X-Real-IP`) e mapeia parâmetros de rota, como o modelo dinâmico na API do **Gemini**.
3. **Execução e *Streaming*:** O conector avalia se o cliente solicitou *streaming* (através de *flags* no corpo do pedido ou parâmetros *query*). Consoante o caso, delega a execução para o método `generate()` (síncrono) ou `generateStream()` da respetiva porta.
4. **Resposta:** Os resultados unários são diretamente serializados para JSON. Em contraste, as respostas em *streaming* originam um `Flow` reativo, onde cada evento emitido é individualmente serializado em JSON e transmitido de forma progressiva ao cliente através de *Server-Sent Events* (**SSE**).

5.6 Implementação do `HttpTransportClient` em Ktor

A abstração de chamadas **HTTP** de saída é garantida pela interface `HttpTransportClient`, descrita na Secção 4.1.4. A implementação concreta fornecida pelo *SDK*, `KtorHttpTransportClient`, assenta no cliente **HTTP Ktor** e reside no módulo `contracts:ktor-http`.

Esta implementação suporta retentativas configuráveis com atraso temporal entre tentativas (*delay*), tratamento explícito de exceções de rede (traduzidas para `NetworkError`) e falhas de *parsing* de JSON (traduzidas para `SerializationError`). Suporta ainda a integração transparente com o *plugin* nativo de **SSE** do **Ktor** para o consumo de respostas progressivas.

A configuração do cliente subjacente é centralizada em `PlatformHttpClient`, que padroniza tempos limite (*timeouts*) de ligação e *socket*, bem como o processo de *Content Negotiation*. Um aspeto fulcral desta organização é o facto de a configuração base ser resolvida por implementações específicas de plataforma (**JVM** ou **JavaScript**). Isto permite ao *SDK* funcionar corretamente como biblioteca **Kotlin Multiplatform**.

Esta arquitetura permite adaptar o comportamento da camada **HTTP** ao contexto de execução sem alterar os *adapters* dos fornecedores. Durante os testes, por exemplo, os *outbounds* podem comunicar com implementações fictícias em memória, evitando dependências de rede externa. Já em ambientes produtivos, a implementação base pode ser substituída por variantes com características específicas definidas pelo consumidor do **OmniAI SDK**, mantendo inalterada a lógica de abstração e tradução dos contratos dos diferentes fornecedores de Inteligência Artificial.

5.7 Implementações Inbound e Outbound

O lógico central da **OmniAI Gateway** materializa-se nos *adapters* de entrada (*inbounds*) e saída (*outbounds*). Cada *adapter* é rigorosamente desenhado em torno do padrão Porta-Adaptador e apoiado num *Translator* dedicado. Esta separação permite que a realização do pedido e o mapeamento físico de atributos JSON vivam em componentes distintos, facilitando testes isolados. A Figura 5.1 ilustra a arquitetura base de tradução.




Figura 5.1: Arquitetura de Tradução e Fluxo de Dados entre Contratos e Domínio Comum

5.8 Translators de Entrada (Inbound)

Os *Inbound Translators* são responsáveis por converter os contratos específicos de cada fornecedor de inferência para o modelo de domínio comum do **OmniAI SDK** e por realizar o processo inverso na geração de respostas. Além da tradução de pedidos e respostas completas, estes componentes também adaptam eventos incrementais de *streaming* para o formato esperado por cada API.

5.8.1 OpenAI Inbound Translator

A implementação `OpenAiInboundTranslator` adapta os contratos compatíveis com a API da **OpenAI** para o domínio comum.

Contrato Inbound (OpenAI)	Mapeamento para CommonRequest
<code>temperature, maxTokens, topP</code>	Integrados na <code>CommonGenerationConfig</code> . O campo <code>model</code> é mapeado diretamente para o nível superior do <code>CommonRequest</code> .
<code>stop</code>	É convertido para uma <code>List<String></code> , distinguindo automaticamente entre valores únicos (<code>Single</code>) e múltiplos (<code>Multiple</code>).
<code>messages[].role</code>	Convertido para os papéis do domínio comum: <code>SYSTEM</code> , <code>ASSISTANT</code> , <code>TOOL</code> e <code>USER</code> . Valores não reconhecidos são tratados como <code>USER</code> .
<code>messages[].content & toolCalls</code>	O conteúdo textual não vazio origina instâncias de <code>TextPart</code> . As chamadas de ferramentas são convertidas em <code>ToolCallPart(toolCallId, functionName)</code> , com os argumentos encapsulados num mapa sob a chave <code>"raw"</code> ; se o identificador vier omissa, é gerado no formato <code>"openai-tool-call-\$index"</code> . Quando o papel é <code>TOOL</code> e existem <code>toolCallId</code> e conteúdo, é gerado um <code>ToolResultPart</code> , convertendo o conteúdo textual para valor JSON.
<code>tools[].function</code>	Convertido para <code>CommonTool(name, description, parametersSchema)</code> , extraíndo as propriedades definidas no schema da ferramenta. Se a descrição estiver ausente, é usado o nome da função; se os parâmetros estiverem ausentes, o schema fica vazio.
<code>toolChoice</code>	Converte os valores <code>auto</code> , <code>none</code> e <code>required</code> para os respectivos tipos do domínio comum (<code>ToolChoice.Auto</code> , <code>ToolChoice.None</code> e <code>ToolChoice.Required</code>), podendo também representar a seleção explícita de uma função específica.
<code>responseFormat</code>	Verifica se o tipo corresponde a <code>"json_object"</code> ou <code>"json_schema"</code> , ativando a opção <code>jsonResponse</code> .
<code>stream, frequencyPenalty, presencePenalty, n, seed, user, logitBias, logProbs, topLogProbs, responseFormat</code>	Armazenados na <code>TypedMap (providerOptions)</code> do <code>CommonRequest</code> , preservando opções específicas do fornecedor que não possuem representação no domínio comum.

Tabela 5.2: Mapeamento Inbound: **OpenAI** Request para o Domínio Comum

No sentido inverso, a tradução da resposta converte os objetos do domínio comum para a estrutura nativa da API da **OpenAI**.

Domínio Comum	Mapeamento para Contrato Resposta (OpenAI)
<code>id & created</code>	Utiliza o <code>id</code> nativo ou gera um identificador no formato <code>chatcmpl-UUID</code> . O instante temporal é recuperado das <code>providerOptions</code> ou gerado pelo <code>Clock.System</code> ; o <code>systemFingerprint</code> , quando existe, também é recuperado das <code>providerOptions</code> .
<code>choices[].message.role</code>	Convertido de <code>CommonRole</code> para os papéis nativos da OpenAI : <code>system</code> , <code>user</code> , <code>assistant</code> ou <code>tool</code> .
<code>choices[].message.content</code>	O conteúdo é obtido através de <code>firstRenderableContentOrNull()</code> , juntando os <code>TextPart</code> com quebras de linha. Se não existir texto, recorre ao primeiro <code>RefusalPart</code> ou à representação textual do primeiro <code>JsonPart</code> .
<code>choices[].message.toolCalls</code>	Um <code>ToolCallPart</code> é convertido para um <code>OpenAiToolCallOutput</code> , formatando os <code>argumentsJson</code> numa única representação textual.
<code>choices[].finishReason</code>	Converte <code>STOP</code> para <code>stop</code> , <code>LENGTH</code> para <code>length</code> , <code>TOOL_CALL</code> para <code>tool_calls</code> e <code>CONTENT_FILTER</code> para <code>content_filter</code> . Valores <code>OTHER</code> ou nulos não são emitidos.
<code>usage</code>	Mapeia <code>inputTokens</code> , <code>outputTokens</code> e <code>totalTokens</code> para <code>promptTokens</code> , <code>completionTokens</code> e <code>totalTokens</code> , respetivamente.

Tabela 5.3: Mapeamento Inbound: Domínio para **OpenAI** Response Unária

Para respostas em *streaming*, os eventos internos do domínio são convertidos para os *chunks* SSE utilizados pela **OpenAI**.

Common Response Event	Mapeamento para Stream Chunk (OpenAI)
<code>ResponseStarted</code>	Emite Chunk inicial. <code>choices</code> ficam vazias.
<code>ChoiceStarted</code>	Emite Chunk com índice da <i>choice</i> . O <code>delta</code> contém apenas a definição do <code>role</code> ; se o papel vier ausente, assume <code>assistant</code> .
<code>TextDeltaEvent</code>	Emite Chunk com <code>delta.content</code> preenchido pelo texto.
<code>ToolCallStartedEvent</code>	Emite Chunk inicializando o delta de <code>toolCalls</code> : define o <code>id</code> , a <code>type="function"</code> e o nome da função (<code>arguments=</code>).
<code>ToolCallArguments DeltaEvent</code>	Emite Chunk contendo fragmentos incrementais em <code>function.arguments</code> . O nome da função é omitido neste pacote.
<code>ChoiceFinished</code>	Emite Chunk apenas com a tradução do <code>finishReason</code> ; o <code>delta</code> não é preenchido.
<code>UsageReported</code>	Emite Chunk especial sem <i>choices</i> , transportando o objeto global <code>usage</code> .
<code>ResponseCompleted</code>	Emite Chunk sem <i>choices</i> , sinalizando a conclusão bem-sucedida do <i>stream</i> .
<code>ResponseErrored</code>	Emite Chunk injetando a mensagem de erro como texto no <code>delta.content</code> .

Tabela 5.4: Mapeamento Inbound: Domínio para **OpenAI** Streaming (`fromDomainEvent`)

5.8.2 Anthropic Inbound Translator

O `AnthropicInboundTranslator` adapta os contratos compatíveis com a *Messages API* da **Anthropic** para o domínio comum.

Contrato Inbound (Anthropic)	Mapeamento para CommonRequest
<code>temperature</code> , <code>maxTokens</code> , <code>topP</code> , <code>stopSequences</code>	Agrupados na <code>CommonGenerationConfig</code> . O campo <code>model</code> , por sua vez, fica mapeado logo na raiz do <code>CommonRequest</code> .
<code>system</code>	O conteúdo de sistema é convertido para <code>SystemPrompt</code> . Quando chega como <code>RawText</code> , o texto é usado diretamente; quando chega como lista de blocos, apenas os blocos <code>Text</code> são unidos com <code>joinToString()</code> . Se o resultado estiver em branco, é ignorado.
<code>messages[] .role</code>	Convertido para os enums de domínio: <code>SYSTEM</code> , <code>ASSISTANT</code> , <code>TOOL</code> ou <code>USER</code> . Valores não reconhecidos são tratados como <code>USER</code> .
<code>messages[] .content</code>	O <code>Text</code> passa a <code>TextPart</code> . O <code>ToolUse</code> dá origem a um <code>ToolCallPart(id, name, input)</code> , gerando um ID automático ("anthropic-tool-use-\$index") se for necessário. O <code>ToolResult</code> é encapsulado num <code>ToolResultPart</code> . Nota: Blocos de <code>Thinking</code> (raciocínio interno) que venham no input são ignorados e retornam <code>null</code> .
<code>tools</code>	A lista é mapeada para instâncias de <code>CommonTool</code> . O <code>inputSchema</code> original é convertido para <code>JsonObject</code> e guardado no campo <code>parametersSchema</code> ; se não for um objeto JSON, o schema fica vazio.
<code>toolChoice</code>	Traduzido diretamente: <code>auto</code> para <code>Auto</code> , <code>none</code> para <code>None</code> , <code>any</code> para <code>Required</code> , e os casos de <code>tool</code> passam a <code>Specific(name)</code> .
(Constantes da Integração)	O <code>provider</code> fica definido estaticamente como <code>Provider.ANTHROPIC</code> e o <code>jsonResponse</code> assume sempre o valor <code>false</code> .
<code>stream</code> , <code>topK</code> , <code>stopToken</code> , <code>thinking</code> , <code>metadata</code>	Por serem opções específicas e mais avançadas, são guardadas no <code>TypedMap (providerOptions)</code> dentro do <code>CommonRequest</code> .

Tabela 5.5: Mapeamento Inbound: Request da **Anthropic** para o Domínio

No sentido inverso, a resposta do domínio comum é convertida para o formato **Anthropic MessageResponse**.

Domínio Comum	Mapeamento para Contrato Resposta (Anthropic)
<code>id & model</code>	Utiliza diretamente os valores de <code>id</code> e <code>model</code> da <code>CommonResponse</code> . A resposta nativa é construída a partir da primeira <code>choice</code> ; se não existir, o conteúdo fica vazio e o papel assume <code>assistant</code> .
<code>choices[] .message .role</code>	Convertido de <code>CommonRole</code> para o papel nativo. <code>USER</code> passa a <code>user</code> ; <code>SYSTEM</code> , <code>ASSISTANT</code> e <code>TOOL</code> passam a <code>assistant</code> .
<code>choices[] .message .content</code>	O conteúdo é convertido preservando os elementos nativos: <code>TextPart</code> gera <code>Text</code> , <code>ToolCallPart</code> origina <code>ToolUse</code> preservando a hierarquia do JSON interno, <code>JsonPart</code> é serializado como texto JSON, e os <code>RefusalPart</code> são omitidos do mapeamento.
<code>choices[] .finishReason</code>	Convertido para <code>end_turn</code> , <code>max_tokens</code> , <code>tool_use</code> e <code>stop_sequence</code> . Valores <code>OTHER</code> ou nulos não são emitidos.
<code>usage</code>	Mapeado para o correspondente <code>AnthropicUsage</code> (<code>inputTokens</code> e <code>outputTokens</code>).

Tabela 5.6: Mapeamento Inbound: Domínio para **Anthropic** Message Response Unária

Em modo *streaming*, os eventos do domínio são traduzidos para os eventos **SSE** definidos pela **Anthropic**.

Common Response Event	Mapeamento para Evento SSE (Anthropic)
<code>ResponseStarted</code>	Retorna um evento <code>MessageStart</code> com o <code>id</code> e o <code>model</code> do evento de domínio, assumindo o papel de <code>role="assistant"</code> .
<code>ChoiceStarted</code>	Emite um <code>ContentBlockStart</code> com o índice da <i>choice</i> correspondente, indicando o início de um bloco de <code>Text</code> .
<code>TextDeltaEvent</code>	O fragmento de texto (<code>text</code>) é repassado de forma direta para o evento SSE <code>ContentBlockDelta(TextDelta)</code> .
<code>ToolCallStartedEvent</code>	Inicia o bloco com um <code>ContentBlockStart(ToolUse)</code> , mantendo o <code>id</code> e o <code>name</code> originais, e inicializando a chamada com um <code>JsonObject</code> vazio.
<code>ToolCallArgumentsDeltaEvent</code>	Encaminha os fragmentos parciais dos argumentos recebidos para um evento SSE do tipo <code>ContentBlockDelta(InputJsonDelta)</code> .
<code>ChoiceFinished</code>	Gera um evento <code>MessageDelta</code> que inclui o motivo de paragem (<code>stopReason</code>) associado a esta <i>choice</i> .
<code>UsageReported</code>	Gera um evento <code>MessageDelta</code> contendo a contagem atualizada de <i>tokens</i> processados.
<code>ResponseCompleted</code>	Emite o evento <code>MessageStop</code> , sinalizando o fecho definitivo da <i>stream</i> .
<code>ResponseErrored</code>	Interrompe a <i>stream</i> com um evento de <code>Error</code> . Faz-se a distinção entre falhas temporárias (<code>overloaded_error</code>) e erros gerais da API (<code>api_error</code>).

Tabela 5.7: Mapeamento Inbound: Eventos **SSE Anthropic** (`fromDomainEvent`)

5.8.3 Gemini Inbound Translator

O `GeminiInboundTranslator` adapta os contratos compatíveis com a API **Gemini** para o domínio comum.

Contrato Inbound (Gemini)	Mapeamento para CommonRequest
<code>generationConfig</code>	As propriedades base (<code>temperature</code> , <code>topP</code> , <code>stopSequences</code>) são extraídas diretamente para a <code>CommonGenerationConfig</code> .
<code>model</code>	O identificador do modelo é lido do contrato recebido. Caso não seja fornecido, assume-se a constante "NO MODEL" como <i>fallback</i> .
<code>systemInstruction</code>	Convertido para um <code>SystemPrompt</code> , agrupando as <code>parts</code> de texto não vazias num único bloco contínuo, separadas por quebras de linha. Se o resultado ficar vazio, o <code>SystemPrompt</code> não é criado.
<code>contents[].role</code>	Adapta os papéis nativos para o domínio: <code>system</code> passa a <code>SYSTEM</code> , <code>model</code> e <code>assistant</code> passam a <code>ASSISTANT</code> , <code>tool</code> e <code>function</code> passam a <code>TOOL</code> , enquanto <code>user</code> se mantém como <code>USER</code> . Valores não reconhecidos são tratados como <code>USER</code> .
<code>contents[].parts</code>	O conteúdo é transformado de acordo com o seu tipo: <code>text</code> gera um <code>TextPart</code> , <code>functionCall</code> origina um <code>ToolCallPart</code> com identificador local "gemini-tool-call-\$index", e <code>functionResponse</code> converte-se em <code>ToolResultPart</code> .
<code>tools[].functionDeclarations</code>	A hierarquia aninhada (<code>tools</code> -> <code>functionDeclarations</code>) é simplificada (<i>flattened</i>) para criar uma lista única de ferramentas (<code>List<CommonTool></code>).
<code>toolConfig</code> <code>.functionCallingConfig</code>	Se existirem <code>allowedFunctionNames</code> , o tradutor cria uma escolha específica. Caso contrário, adapta o modo de execução: <code>auto</code> passa a <code>Auto</code> , <code>none</code> a <code>None</code> , e <code>any</code> ou <code>required</code> a <code>Required</code> .
<code>generationConfig</code> <code>.responseMimeType</code>	A <i>flag</i> <code>jsonResponse</code> assume o valor <code>true</code> caso o tipo MIME seja <code>application/json</code> ou se existir um <code>responseJsonSchema</code> explicitamente definido.
<code>topK</code> , <code>thinkingConfig</code> , <code>responseMimeType</code> , <code>responseJsonSchema</code>	Por se tratarem de configurações específicas do Gemini , são guardadas no <code>TypedMap</code> (<code>providerOptions</code>) do <code>CommonRequest</code> .

Tabela 5.8: Mapeamento Inbound: Request da **Gemini** para o Domínio

No sentido inverso, a resposta do domínio comum é convertida para o formato `Gemini GenerateContentResponse`.

Domínio Comum	Mapeamento para Contrato Resposta (Gemini)
<code>id & model</code>	São atribuídos de forma direta aos campos <code>responseId</code> e <code>modelVersion</code> do Gemini .
<code>choices</code>	Dão origem aos respetivos objetos GeminiCandidate , preservando o índice da resposta. A conversão de papéis é feita no sentido inverso: SYSTEM e ASSISTANT passam a <code>"model"</code> , TOOL a <code>"function"</code> , e USER mantém-se como <code>"user"</code> .
<code>choices[].message</code> <code>.content</code>	De forma simétrica, o conteúdo é traduzido consoante a sua natureza: um TextPart gera o texto base de um GeminiResponsePart ; um ToolCallPart preenche o nó correspondente à chamada de função; um JsonPart é convertido numa String com o conteúdo JSON; e um RefusalPart é emitido como texto com o motivo da recusa.
<code>choices[].finishReason</code>	Mapeado para os motivos de paragem nativos do Gemini : STOP , MAX_TOKENS ou SAFETY . No caso de TOOL_CALL , a implementação emite STOP ; valores OTHER ou nulos não são emitidos.
<code>usage</code>	Os contadores genéricos do domínio são convertidos e agrupados na estrutura GeminiUsageMetadata , alimentando os campos <code>promptTokenCount</code> , <code>candidatesTokenCount</code> e <code>totalTokenCount</code> .

Tabela 5.9: Mapeamento Inbound: Domínio para **Gemini** Generate Content Response Unária

Durante o fluxo de *streaming* via Server-Sent Events (**SSE**), a API **Gemini** diferencia-se de fornecedores como a **OpenAI** ou a **Anthropic** por não adotar objetos específicos para deltas parciais. Em vez disso, reutiliza a mesma estrutura da resposta unária (**GeminiGenerateContentResponse**) para encapsular cada evento da *stream*. Como consequência, o tradutor mapeia os deltas granulares de domínio (**CommonResponseEvent**) reconstruindo a hierarquia do DTO nativo a cada evento emitido.

Common Response Event	Mapeamento para Evento SSE (Gemini Chunk)
ResponseStarted	Emite uma instância básica contendo apenas os metadados iniciais, como o <code>modelVersion</code> e o <code>responseId</code> .
ChoiceStarted	Inicializa as instâncias de <code>GeminiCandidate</code> , definindo apenas os atributos essenciais, como o índice (<code>index</code>) e o papel (<code>role</code>).
TextDeltaEvent	Encaminha o fragmento de texto (<i>delta</i>) reconstruindo a estrutura aninhada da resposta: <code>candidates[] -> content -> parts[] -> GeminiResponsePart(text)</code> .
ToolCallStartedEvent	Gera um candidato que assinala o início da chamada de função através de um <code>GeminiResponsePart(functionCall)</code> , configurando o seu nome e inicializando os argumentos com um <code>JsonObject</code> vazio.
ToolCallArguments DeltaEvent	Transmite os fragmentos incrementais dos argumentos utilizando uma chave provisória (" <code>partialJson</code> "), que transporta a <i>string</i> bruta para facilitar a posterior reconstrução do <i>payload</i> .
ChoiceFinished	Emite apenas o motivo de paragem (<code>finishReason</code>) correspondente ao término desta resposta parcial (<i>choice</i>); no caso de <code>TOOL_CALL</code> , o valor nativo emitido é <code>STOP</code> .
UsageReported	Emite os contadores de <i>tokens</i> consumidos, encapsulados num objeto <code>GeminiUsageMetadata</code> .
ResponseCompleted	Sinaliza o fim da <i>stream</i> , emitindo um evento com uma estrutura idêntica à do <code>ResponseStarted</code> .
ResponseErrored	Emite uma resposta com <code>GeminiPromptFeedback</code> . Quando o erro é marcado como recuperável, o <code>blockReason</code> recebe o prefixo <code>TRANSIENT_ERROR</code> ; nos restantes casos, recebe o prefixo <code>ERROR</code> .

Tabela 5.10: Mapeamento Inbound: Eventos **SSE Gemini** (`fromDomainEvent`)

5.9 Translators de Saída (Outbound)

Os *Outbound Translators* ligam o modelo de domínio comum do **OmniAI SDK** às APIs externas usadas pelo *gateway*. No envio, constroem o pedido nativo de cada fornecedor a partir de um `CommonRequest`. Na receção, fazem o percurso inverso: convertem respostas completas e eventos de *streaming SSE* para `CommonResponse` e `CommonResponseEvent`. As opções que pertencem ao domínio comum ficam explícitas no contrato comum, enquanto detalhes específicos de cada fornecedor são preservados através de `providerOptions`.

5.9.1 OpenAI Outbound Translator

A implementação `OpenAiOutboundTranslator` adapta o `CommonRequest` ao formato de *chat completions* da **OpenAI**. Os campos comuns são mapeados diretamente sempre que possível, e as opções próprias da **OpenAI** são lidas da `TypedMap` de *provider*.

Domínio Comum	Mapeamento para Contrato Saída (OpenAI Request)
<code>model</code>	Mapeado de forma direta.
<code>messages[].content</code>	Os blocos <code>TextPart</code> são unidos com quebras de linha. Os <code>ToolCallPart</code> são convertidos em <code>OpenAiToolCall(id, function(name, arguments))</code> , usando a representação textual dos argumentos. Quando a mensagem tem papel <code>TOOL</code> , o primeiro <code>ToolResultPart</code> preenche o <code>content</code> e o respetivo <code>toolCallId</code> .
<code>config</code>	<code>temperature</code> , <code>maxTokens</code> e <code>topP</code> são transferidos para o pedido nativo. O <code>maxTokens</code> é limitado com <code>coerceAtMost(4000)</code> e assume 1000 por defeito. As <code>stopSequences</code> são convertidas para <code>OpenAiStop</code> .
<code>providerOptions</code>	São lidas, quando existem, as opções específicas <code>frequencyPenalty</code> , <code>presencePenalty</code> , <code>n</code> , <code>stream</code> , <code>seed</code> , <code>user</code> , <code>logitBias</code> , <code>logProbs</code> e <code>topLogProbs</code> .
<code>tools</code>	Cada <code>CommonTool</code> é convertido para <code>OpenAiFunctionDefinition(name, description, parameters)</code> dentro de um <code>OpenAiTool</code> .
<code>toolChoice</code>	Traduz <code>Auto</code> , <code>None</code> e <code>Required</code> para os modos nativos <code>auto</code> , <code>none</code> e <code>required</code> . Nos casos específicos, força a função através de <code>OpenAiToolChoice.Function</code> .
<code>jsonResponse</code>	Quando <code>jsonResponse</code> está ativo, define <code>OpenAiResponseFormat(type = "json_object")</code> .

Tabela 5.11: Mapeamento Outbound: `CommonRequest` para **OpenAI** Request

Na receção de uma resposta unária, o tradutor converte a resposta da **OpenAI** para o modelo comum e preserva metadados úteis do fornecedor.

Contrato Resposta (OpenAI)	Mapeamento para o Domínio
<code>id & model</code>	Mapeados diretamente para <code>CommonResponse</code> . Os campos <code>created</code> e <code>systemFingerprint</code> , quando presentes, são guardados em <code>providerOptions</code> .
<code>choices[].message.role</code>	Convertido para <code>CommonRole</code> . Se o papel vier omissso, é assumido <code>assistant</code> .
<code>choices[].message.content</code>	O conteúdo textual é convertido para <code>TextPart</code> . Se o texto aparentar conter um objeto ou lista JSON e o <code>parse</code> for válido, é convertido para <code>JsonPart</code> . As <code>toolCalls</code> da mensagem ou do <code>delta</code> são convertidas para <code>ToolCallPart</code> .
<code>choices[].finishReason</code>	Converte <code>stop</code> , <code>length</code> , <code>tool_calls</code> e <code>content_filter</code> para os motivos comuns correspondentes; valores desconhecidos ficam como <code>OTHER</code> .
<code>usage</code>	Mapeia <code>promptTokens</code> , <code>completionTokens</code> e <code>totalTokens</code> para <code>inputTokens</code> , <code>outputTokens</code> e <code>totalTokens</code> .

Tabela 5.12: Mapeamento Outbound: **OpenAI** Response Unária para Domínio

Para respostas em *streaming* via **SSE**, o tradutor mantém o `id` e o `model` entre eventos, porque nem todos os *chunks* da **OpenAI** repetem esses metadados.

Evento SSE (OpenAI)	Mapeamento para Common Response Event
Estado do fluxo (<code>runningFold</code>)	Mantém um <code>OpenAiEventContext</code> com o último <code>id</code> e <code>model</code> conhecidos, reutilizando-os nos eventos seguintes quando o <code>chunk</code> não os inclui.
<code>choices.first().delta</code>	Um <code>delta.role</code> origina <code>ChoiceStarted</code> . Um <code>delta.content</code> origina <code>TextDeltaEvent</code> .
<code>delta.toolCalls</code>	Se os argumentos parciais têm conteúdo e o nome da função está ausente, o evento é traduzido para <code>ToolCallArgumentsDeltaEvent</code> . Caso contrário, inicia uma chamada de ferramenta com <code>ToolCallStartedEvent</code> .
<code>finishReason</code>	Quando a <code>choice</code> inclui motivo de conclusão, é emitido <code>ChoiceFinished</code> com o <code>finishReason</code> convertido para o domínio comum.
<code>usage</code>	Quando chega num <code>chunk</code> sem <code>choices</code> , é convertido para <code>UsageReported</code> .
Done ou Chunk final	O fim explícito do fluxo, ou um objeto que já não corresponde a <code>chat.completion.chunk</code> , é traduzido para <code>ResponseCompleted</code> .
Error	Gera <code>ResponseErrored</code> . O erro só é marcado como <code>retryable</code> quando o tipo é <code>server_error</code> , <code>rate_limit_error</code> ou <code>temporarily_unavailable</code> .

Tabela 5.13: Mapeamento Outbound: **OpenAI** Streaming para Domínio (`toDomainEvent`)

5.9.2 Anthropic Outbound Translator

O `AnthropicOutboundTranslator` adapta o domínio comum à *Messages API* da **Anthropic**. O `systemPrompt` é enviado no campo próprio `system`, enquanto mensagens, ferramentas e opções específicas são organizadas segundo o contrato nativo.

Domínio Comum	Mapeamento para Contrato Saída (Anthropic Request)
<code>system</code>	O <code>systemPrompt</code> é convertido para <code>RawText</code> quando contém texto não vazio.
<code>messages[].role</code>	<code>USER</code> é convertido para <code>user</code> ; <code>SYSTEM</code> , <code>ASSISTANT</code> e <code>TOOL</code> são enviados como <code>assistant</code> .
<code>messages[].content</code>	Uma mensagem com um único <code>TextPart</code> é enviada como <code>RawText</code> . Nos restantes casos, é criado um <code>ListContentBlock</code> : <code>TextPart</code> gera <code>Text</code> , <code>ToolCallPart</code> gera <code>ToolUse</code> , <code>ToolResultPart</code> gera <code>ToolResult</code> e <code>JsonPart</code> é enviado como texto JSON.
<code>config</code>	Mapeia <code>temperature</code> , <code>topP</code> e <code>stopSequences</code> . O <code>maxTokens</code> usa o valor configurado ou 1024 por defeito.
<code>providerOptions</code>	Inclui opções próprias da Anthropic , como <code>stream</code> , <code>topK</code> , <code>stopToken</code> , <code>thinking</code> e <code>metadata</code> .
<code>tools</code>	Cada <code>CommonTool</code> é convertido para <code>AnthropicToolDefinition(name, description, inputSchema)</code> .
<code>toolChoice</code>	Converte <code>Auto</code> , <code>None</code> e <code>Required</code> para <code>auto</code> , <code>none</code> e <code>any</code> . Uma escolha específica é enviada como <code>type = "tool"</code> com o nome da função.

Tabela 5.14: Mapeamento Outbound: `CommonRequest` para **Anthropic** Request

Na receção de uma resposta unária da **Anthropic** (`AnthropicMessageResponse`), o tradutor cria uma única `CommonChoice` e converte cada bloco de conteúdo para a representação comum.

Contrato Resposta (Anthropic)	Mapeamento para o Domínio
id & model	Mapeados diretamente para <code>CommonResponse</code> ; a resposta é representada numa <code>CommonChoice</code> com índice 0.
content[].type == text	Convertido para <code>TextPart</code> .
content[].type == tool_use	Convertido para <code>ToolCallPart</code> , preservando o <code>id</code> , o nome da função e as propriedades do <code>input</code> .
content[].type == thinking	Como este tradutor não tem um bloco próprio para <code>thinking</code> no domínio comum, o conteúdo é preservado como <code>RefusalPart(reason = thinking)</code> .
stopReason	Converte <code>end_turn</code> , <code>max_tokens</code> , <code>tool_use</code> e <code>stop_sequence</code> para os motivos comuns correspondentes.
usage	Mapeia <code>inputTokens</code> e <code>outputTokens</code> ; o total é calculado a partir desses dois valores quando disponíveis.

Tabela 5.15: Mapeamento Outbound: **Anthropic** Response Unária para Domínio

Em *streaming SSE*, a **Anthropic** já separa o fluxo em eventos tipados. O tradutor converte cada tipo de evento para o evento comum correspondente e mantém em contexto o `id` e o `model` recebidos no início da mensagem.

Evento SSE (Anthropic)	Mapeamento para Common Response Event
Estado do fluxo (runningFold)	Mantém um <code>AnthropicEventContext</code> com o <code>id</code> e o <code>model</code> da mensagem, reutilizando-os nos eventos seguintes do mesmo fluxo.
MessageStart	Convertido para <code>ResponseStarted</code> , usando o <code>id</code> e o <code>model</code> da mensagem nativa.
ContentBlockStart	Um bloco <code>Text</code> origina <code>ChoiceStarted</code> . Um bloco <code>ToolUse</code> origina <code>ToolCallStartedEvent</code> . Um bloco <code>Thinking</code> também inicia uma <i>choice</i> de assistente.
ContentBlockDelta	<code>TextDelta</code> , <code>SignatureDelta</code> e <code>ThinkingDelta</code> são convertidos para <code>TextDeltaEvent</code> . <code>InputJsonDelta</code> é convertido para <code>ToolCallArgumentsDeltaEvent</code> .
ContentBlockStop	Convertido para <code>ChoiceFinished</code> no índice do bloco recebido.
MessageDelta	Quando inclui <code>usage</code> , gera <code>UsageReported</code> ; caso contrário, gera <code>ChoiceFinished</code> com o <code>stopReason</code> convertido.
MessageStop	Convertido para <code>ResponseCompleted</code> .
Ping	Mantém o fluxo ativo e é representado como <code>ResponseStarted</code> .
Error	Gera <code>ResponseErrored</code> . O campo <code>retryable</code> é marcado quando o tipo de erro contém <code>overloaded</code> .

Tabela 5.16: Mapeamento Outbound: **Anthropic** Streaming para Domínio (toDomainEvent)

5.9.3 Gemini Outbound Translator

O `GeminiOutboundTranslator` adapta o domínio comum ao formato `GenerateContent` da API **Gemini**. A implementação trata ainda diferenças próprias da plataforma, como a limpeza dos JSON *schemas* de ferramentas e a forma como os eventos progressivos reutilizam a estrutura de

resposta completa.

Domínio Comum	Mapeamento para Contrato Saída (Gemini Request)
<code>systemInstruction</code>	O <code>systemPrompt</code> é convertido para <code>GeminiSystemInstruction</code> , contendo uma lista de <code>GeminiPart</code> com o texto do <i>prompt</i> sistêmico.
<code>messages[].content</code>	<code>TextPart</code> é enviado como texto. <code>ToolCallPart</code> gera <code>functionCall</code> e inclui <code>thoughtSignature = "skip_thought_signature_validator"</code> . <code>ToolResultPart</code> gera <code>functionResponse</code> . <code>JsonPart</code> é enviado como texto JSON.
<code>config</code>	<code>stopSequences</code> , <code>temperature</code> e <code>topP</code> são colocados em <code>GeminiGenerationConfig</code> . As opções <code>topK</code> , <code>thinkingConfig</code> , <code>responseMimeType</code> e <code>responseJsonSchema</code> são lidas de <code>providerOptions</code> ; quando <code>jsonResponse</code> está ativo, o <code>responseMimeType</code> passa a <code>application/json</code> .
<code>tools & cleanGeminiParameters</code>	As ferramentas são agrupadas num <code>GeminiTool</code> com <code>functionDeclarations</code> . O <code>parametersSchema</code> é limpo recursivamente para remover chaves não suportadas (<code>\$schema</code> , <code>additionalProperties</code> , <code>propertyNames</code> , <code>title</code> , <code>default</code> , <code>\$id</code> , <code>exclusiveMinimum</code>); valores <code>const</code> são convertidos para <code>enum</code> .
<code>toolChoice</code>	Converte <code>Auto</code> , <code>None</code> e <code>Required</code> para os modos <code>AUTO</code> , <code>NONE</code> e <code>ANY</code> . Em escolhas específicas, usa <code>ANY</code> com <code>allowedFunctionNames</code> .

Tabela 5.17: Mapeamento Outbound: `CommonRequest` para **Gemini** Request

Na resposta unária `GeminiGenerateContentResponse`, o tradutor percorre os candidatos devolvidos e converte as partes reconhecidas para o domínio comum.

Contrato Resposta (Gemini)	Mapeamento para o Domínio
<code>id & model</code>	Usa <code>responseId</code> quando existe; se estiver ausente, gera um identificador local por UUID. O <code>modelVersion</code> é usado como modelo e, se vier ausente, fica vazio.
<code>candidates[].parts</code>	Partes de texto geram <code>TextPart</code> . Partes <code>functionCall</code> geram <code>ToolCallPart</code> , com <code>toolCallId</code> local <code>gemini-tool-call-0</code> e argumentos convertidos a partir de <code>args</code> .
<code>candidates[].finishReason</code>	Se a resposta contém chamadas de ferramenta, o motivo comum fica como <code>TOOL_CALL</code> . Caso contrário, <code>STOP</code> , <code>MAX_TOKENS</code> e <code>SAFETY</code> são convertidos para <code>STOP</code> , <code>LENGTH</code> e <code>CONTENT_FILTER</code> .
<code>promptFeedback</code>	Quando existe, o motivo de bloqueio é preservado em <code>providerOptions</code> sob a chave <code>promptFeedback</code> .
<code>usageMetadata</code>	Mapeia <code>promptTokenCount</code> , <code>candidatesTokenCount</code> e <code>totalTokenCount</code> para a estrutura comum de utilização.

Tabela 5.18: Mapeamento Outbound: **Gemini** Response Unária para Domínio

Nos eventos progressivos da API **Gemini**, cada *chunk* chega com a mesma estrutura de `GeminiGenerateContentResponse`. O tradutor analisa o conteúdo disponível em cada emissão e produz o evento comum correspondente.

Evento SSE (Gemini)	Mapeamento para Common Response Event
Estado do fluxo (<code>runningFold</code>)	Mantém um <code>GeminiEventContext</code> com o último <code>id</code> e <code>model</code> conhecidos, para preencher eventos seguintes quando o <code>chunk</code> não repete esses dados.
<code>promptFeedback</code>	Quando inclui <code>blockReason</code> , gera <code>ResponseErrored</code> . O erro é marcado como <code>retryable</code> quando o motivo contém <code>TRANSIENT</code> .
<code>candidates</code> vazio	Se existir <code>usageMetadata</code> , gera <code>UsageReported</code> ; caso contrário, assinala o início do fluxo com <code>ResponseStarted</code> .
<code>finishReason</code>	Quando presente num candidato, gera <code>ChoiceFinished</code> com o motivo convertido para o domínio comum.
<code>functionCall</code>	Se o nome da função está presente, inicia a chamada com <code>ToolCallStartedEvent</code> . Como a Gemini não fornece identificador de ferramenta neste ponto, é criado um <code>toolCallId</code> local no formato <code>gemini-tool-call-{Random}</code> . Se o nome está ausente mas existem argumentos, emite <code>ToolCallArgumentsDeltaEvent</code> ; a chave <code>partialJson</code> é usada quando existe, caso contrário é usada a representação textual dos argumentos.
<code>text</code>	Um fragmento textual em <code>parts</code> é convertido para <code>TextDeltaEvent</code> .
<code>content.role</code>	Quando o <code>chunk</code> apenas indica o papel da resposta, é emitido <code>ChoiceStarted</code> .
<code>Done</code>	Convertido para <code>ResponseCompleted</code> .
<code>Error</code>	Gera <code>ResponseErrored</code> . O campo <code>retryable</code> é marcado para estados <code>UNAVAILABLE</code> , <code>RESOURCE_EXHAUSTED</code> , <code>DEADLINE_EXCEEDED</code> , <code>ABORTED</code> e <code>INTERNAL</code> .

Tabela 5.19: Mapeamento Outbound: **Gemini** Streaming para Domínio (`toDomainEvent`)

5.10 Evolução para a Pipeline de Interceptors

A *pipeline* foi implementada como um *adapter* de *dispatcher*. Isto é, os *inbounds* não recebem uma *pipeline*; recebem sempre um `DispatcherPort`. Quando a aplicação escolhe `useNativePipeline`, o **SDK** monta uma `GatewayPipeline` com *interceptors* e um *dispatcher* terminal, e depois expõe essa cadeia através de `PipelineBackedDispatcher`. Se a aplicação não quiser a *pipeline*, pode fornecer diretamente um *dispatcher* próprio através de `useCustomDispatcher`.

Esta decisão evita que a *pipeline* se torne uma dependência obrigatória da arquitetura. Um consumidor que pretenda apenas tradução de contratos e despacho direto pode usar um *dispatcher* simples. Um consumidor que precise de segurança, observabilidade e resiliência pode ativar a *pipeline* nativa. Um consumidor com necessidades próprias pode implementar outro `DispatcherPort`, por exemplo com seleção por custo, políticas externas, filas internas ou integração com outro orquestrador.

Modo de montagem	Componente visto pelos inbounds	Justificação
Dispatcher direto	Uma implementação de <code>DispatcherPort</code> .	Útil quando se pretende uma Gateway mínima, com tradução e envio para <i>outbounds</i> sem lógica transversal.
Pipeline nativa	<code>PipelineBackedDispatcher</code> , também exposto como <code>DispatcherPort</code> .	Permite aplicar autenticação, autorização, métricas, <i>rate limiting</i> , <i>circuit breaker</i> , <i>fallback</i> e <i>logging</i> sem alterar <i>adapters</i> .
Dispatcher customizado	Qualquer implementação externa de <code>DispatcherPort</code> .	Mantém o SDK aberto a estratégias futuras, incluindo roteamento por custo, latência, plano de cliente ou políticas de negócio.

Tabela 5.20: Formas de expor a execução aos *inbounds* sem os acoplar à *pipeline*




Figura 5.2: Visão conceitual da *pipeline* de *interceptors*

Esta forma mantém a arquitetura simples. Para um caso mínimo, a **Gateway** pode operar com um *dispatcher* direto. Para um caso operacional, a *pipeline* permite adicionar autenticação,

autorização, métricas, limites, *circuit breaker*, *fallback*, *logging* e *tracing* sem alterar *adapters*. O modelo é semelhante ao dos filtros de **Servlets** [9]: cada filtro recebe um contexto, decide se continua a cadeia e pode executar lógica antes e depois do próximo elemento. A diferença é que, no **OmniAI SDK**, o contexto não representa apenas um pedido **HTTP**; representa uma chamada de inferência já normalizada, incluindo fornecedor, modelo, modo de execução, atributos tipados e eventual fluxo de *streaming*.

A *pipeline* é composta por `GatewayPipeline`, `GatewayPipelineChain`, `Interceptor` e `GatewayContext`. O `GatewayContext` transporta o pedido comum, atributos tipados e modo de execução, podendo representar chamadas síncronas ou *streaming*. A cadeia executa os *interceptors* por ordem e, no fim, invoca o *dispatcher* terminal.

Esta abordagem também prepara o escalamento horizontal. A *pipeline* não exige estado global obrigatório; cada pedido transporta o seu contexto. Onde existe estado partilhável, como *rate limiting* ou *circuit breaker*, o **SDK** define *stores* substituíveis. A implementação em memória é adequada para desenvolvimento e instância única, mas pode ser trocada por **Redis**, base de dados ou outro *backend* coordenado em implantações distribuídas. Assim, várias instâncias da **OmniAI Gateway** podem partilhar contadores, estados de circuito e metadados operacionais sem alterar o contrato dos *inbounds* nem a forma como os clientes chamam a **Gateway**.

5.11 Arquitetura Interna dos Interceptors

O módulo `interceptors` inclui implementações pré-construídas para preocupações operacionais e de segurança. Todos seguem o mesmo contrato: recebem um `GatewayContext`, consultam ou acrescentam atributos à `TypedMap`, decidem se chamam `chain.proceed(context)` e podem observar ou transformar o `PipelineResult`. Esta estrutura permite colocar lógica transversal antes e depois da inferência sem acoplar essa lógica aos *adapters* de entrada, aos *adapters* de saída ou ao *dispatcher*.

A ordem de execução é configurável. No *target JVM*, o **SDK** suporta a anotação `InterceptorPriority`, usada para executar primeiro *interceptors* com prioridade superior. No *target JavaScript*, onde a reflexão sobre anotações é limitada, a ordem segue a sequência definida pela DSL. Assim, autenticação e autorização podem ocorrer no início da cadeia, enquanto métricas, *tracing* e *logging* podem envolver a execução completa.

A motivação para estes *interceptors* não foi apenas organizar código, mas tornar explícitas políticas que, numa **Gateway** de IA, afetam segurança, custo e disponibilidade. A Tabela 5.21 resume essa relação.

Interceptor	Problema tratado	Motivo para estar na Gateway
Telemetria	Falta de visibilidade sobre latência, erros, <i>tokens</i> e fornecedores.	A Gateway observa todas as chamadas e consegue medir comportamento transversal sem alterar clientes ou <i>adapters</i> .
Autenticação	Necessidade de validar quem apresenta o token antes de consumir modelos pagos.	A Gateway é o recurso protegido e deve validar <i>tokens</i> antes de encaminhar tráfego para fornecedores.
Autorização	Um token válido não implica permissão para todos os modelos ou operações.	A decisão por cliente, ação, fornecedor e modelo deve ser centralizada antes da inferência.
Rate limiting	Risco de abuso, picos de carga e custos inesperados.	A Gateway é o ponto natural para aplicar quotas por cliente, plano, fornecedor ou modelo.
Circuit breaker	Dependências externas podem ficar lentas ou indisponíveis.	A Gateway evita insistir em fornecedores em falha e protege o restante sistema.
Fallback	Uma falha de fornecedor não deve, quando existe alternativa, falhar imediatamente a experiência do cliente.	A Gateway conhece os <i>outbounds</i> disponíveis e pode tentar alternativas mantendo o contrato do cliente.

Tabela 5.21: Justificação dos *interceptors* fornecidos pelo **SDK**

5.11.1 Interceptor de Telemetria e Observabilidade

O **MetricsInterceptor** recolhe dados operacionais essenciais num sistema que intermedeia chamadas a LLMs: latência, sucesso, erro, fornecedor, modelo, cliente e consumo de *tokens*. Estes dados são importantes porque uma **Gateway** centraliza tráfego de vários clientes e fornecedores; sem telemetria, não é possível perceber custos, degradação, falhas por modelo ou impacto de políticas como *fallback*.

A implementação distingue chamadas unárias de *streaming*. Em respostas progressivas, o *interceptor* não bloqueia a execução; usa operadores de fluxo para observar eventos e emitir métricas no encerramento do *stream*. Assim mede a duração total da interação, e não apenas o tempo até ao primeiro fragmento.

A arquitetura segue inversão de dependência através da porta **MetricsPort**. O **OmniAI SDK** define instrumentos comuns, como **counter**, **histogram** e **upDownCounter**, enquanto o *adapter* concreto no *target JVM* exporta para **OpenTelemetry**. O uso do **OpenTelemetry Protocol (OTLP)** foi escolhido porque o **OTLP** define a codificação, transporte e entrega de dados de telemetria entre fontes, coletores e *backends* [45]. Esta escolha evita prender o **OmniAI SDK** a **Prometheus**, **Grafana**, **Datadog** ou outro *backend* específico: o **SDK** emite telemetria num formato aberto, o Collector recebe e processa esses dados, e a infraestrutura decide para onde exportar.

Esta decisão é especialmente importante numa **Gateway** de IA. O mesmo **OmniAI SDK** pode ser usado por uma aplicação simples em desenvolvimento, por um POC local com **Prometheus/Grafana** ou por uma instalação futura com outro *backend* de observabilidade. A

OpenTelemetry apresenta-se precisamente como especificação aberta e agnóstica de fornecedor [41]; por isso, a instrumentação fica no **OmniAI SDK**, mas a escolha operacional do *backend* permanece fora do domínio.




Figura 5.3: Fluxo interno de processamento e lógica de observabilidade para pedidos unários e *streaming*

Para adicionar uma métrica, a aplicação usa a DSL do **gateway-client**. O utilizador pode ativar a latência padrão, acrescentar atributos globais e definir métricas próprias com uma função **value**, que extrai o valor a partir do contexto e do resultado, e uma função **tags**, que acrescenta dimensões de análise.

```

metrics {
  metricsPort = telemetryRuntime.metricsPort
  tracer = telemetryRuntime.tracer

  attributes {
    include(ClientIpMetadataKey, alias = "client.ip")
    attribute("sdk.version") { _, _ -> "1.0.0" }
  }

  defaultLatency {
    enabled = true
    name = "gateway.inference.request.duration"
  }

  customMetrics {
    counter(
      name = "gateway.llm.tokens",
      description = "Total de tokens consumidos",
      unit = "{tokens}"
    ) {
      value { _, result ->
        (result as? PipelineResult.Unary)?.response?.usage?.totalTokens
      }
    }
  }
}

```

Listing 5.1: Configuração de telemetria e métricas personalizadas na DSL

Este desenho separa três responsabilidades: a definição da métrica na DSL, a recolha no *inter-*

ceptor e a exportação no *adapter* de telemetria. Também facilita testes, porque `NoOpMetricsPort` pode ser usado quando a observabilidade está desligada.




Figura 5.4: Observabilidade e métricas operacionais da **OmniAI Gateway**

5.11.2 Interceptor de Autenticação

A autenticação é realizada pelo `AuthenticationInterceptor`. A **Gateway** atua como *Resource Server*: recebe pedidos para recursos protegidos, extrai o *access token* do cabeçalho `Authorization: Bearer <token>` e valida se esse token foi emitido por um servidor de autorização confiável [46–48]. Esta responsabilidade é essencial numa **AI Gateway**, porque a camada central passa a proteger acesso a modelos, custos, quotas e dados operacionais.

A **Gateway** não deve atuar como *Authorization Server*: não emite *tokens*, não gere credenciais dos clientes e não substitui **Logto** ou **Keycloak**. O seu papel é o de API protegida. Por isso, valida *tokens* recebidos, confirma se foram emitidos para a audiência esperada e só depois permite que o pedido avance na *pipeline* para os próximos *interceptors*. Esta separação reduz responsabilidade de segurança dentro do **SDK** e permite integrar diferentes fornecedores de identidade sem alterar o contrato dos clientes.

O fluxo inicia-se no *adapter HTTP*, que propaga o token para o domínio através de metadados. O *interceptor* classifica o token: se tiver três segmentos, é tratado como **JWT**; caso contrário, como token opaco. Esta distinção permite escolher entre validação local por assinatura e validação remota por introspeção.

No modo *OIDC Discovery* (RFC 8414), a **Gateway** obtém dinamicamente metadados do *Authorization Server*, como *issuer*, *jwks_uri* e *endpoint* de introspeção [49]. Todo este fluxo encontra-se ilustrado na Figura 5.4. Para **JWTs**, valida o *kid*, obtém a chave pública no **JWKS**, verifica assinatura e confirma *claims* como *exp*, *nbf*, *iss* e *aud* [50–52]. Para *tokens* opacos, usa introspeção **OAuth2** [53].




Figura 5.5: Sequência **OIDC**: descoberta, **JWKS** e cache de chaves

Para reduzir latência e chamadas repetidas ao servidor de autorização, a implementação inclui `InMemoryKeyCache`, rotação de chaves em *background* e *cooldown* para evitar consultas excessivas quando uma chave não é encontrada. No caso de *tokens* opacos, o `IntrospectionCache` usa *positive caching* para *tokens* ativos e *negative caching* para *tokens* inválidos. Os *tokens* opacos são guardados em cache através de *hash*, evitando manter credenciais em texto limpo em memória.

O resultado é encapsulado em `AuthValidationResult` e guardado na `TypedMap` sob a chave `AUTH_RESULT_KEY`. Isto permite que autorização, métricas e *logging* reutilizem a identidade já validada.




Figura 5.6: Fluxo interno do *interceptor* de autenticação

A **Gateway** final usa **Logto** como *Authorization Server* local [39], executado em **Docker** juntamente com **PostgreSQL**, **OpenTelemetry Collector**, **Prometheus** e **Grafana**. Foram também realizados testes exploratórios com **Keycloak** [54]. A escolha final do **Logto** no POC deveu-se à simplicidade de configuração local, suporte a aplicações *Machine-to-Machine* e facilidade de gerir API Resources durante a validação.

A integração do processo de autenticação é declarada na montagem do *SDK*:

```

security {
  authentication {
    discovery {
      discoveryUrl = "https://auth.example.com/.well-known/openid-configuration"
      expectedAudience = "https://gateway.example.com/api"
      clientId = "gateway-client"
      clientSecret = "secret"
    }
  }
}

```

Listing 5.2: DSL de configuração do *interceptor* de autenticação com **OIDC** Discovery

5.11.3 Interceptor de Autorização

A autorização é separada da autenticação porque responder a “quem é o utilizador?” não é o mesmo que responder a “o que este utilizador pode fazer?”. A autenticação valida identidade; a autorização decide permissões sobre uma ação e um recurso. Esta separação é importante numa **Gateway** multi-cliente, onde um token válido pode não ter permissão para usar todos os modelos, fornecedores ou operações. A distinção entre autenticação e autorização é também a base dos modelos modernos de identidade: a primeira prova identidade, enquanto a segunda concede permissão sobre dados ou ações protegidas [55].

No contexto do projeto, esta separação evita dois problemas. Primeiro, impede que a validação de token seja confundida com autorização total: um cliente autenticado pode estar limitado a um subconjunto de modelos, fornecedores ou quotas. Segundo, permite trocar a origem das decisões de autorização sem alterar a autenticação. Embora numa fase inicial a decisão possa operar de forma local e simples, o sistema está desenhado para que, numa iteração futura, essa mesma decisão possa ser assegurada por um PDP externo, tal como o AuthZen ou o OPA.

No **OmniAI SDK**, a autorização é centralizada no `PolicyEnforcerInterceptor`. O componente atua como *Policy Enforcement Point* (PEP): interceta o pedido, constrói um `AuthorizationInput` e delega a decisão a um *Policy Decision Point* (PDP) através da porta `PolicyDecisionPointPort`. Podemos ver todo este fluxo na figura 5.6.




Figura 5.7: Arquitetura do *interceptor* de autorização: separação entre PEP e PDP

O `AuthorizationInput` segue o padrão **Subject-Action-Resource (SAR)**. O **Subject** representa o utilizador ou aplicação, incluindo identificador, roles e atributos vindos do token. A **Action** representa a operação, como `chat_completion`. O **Resource** identifica o alvo, como fornecedor ou modelo. O **Context** acrescenta atributos ambientais, como IP, tempo ou metadados do pedido. A porta do PDP permite integrar motores diferentes, incluindo políticas internas, AuthZen, OPA ou outro serviço externo. Se a decisão for *Deny*, a *pipeline* é interrompida antes de qualquer chamada ao fornecedor [56].

A configuração de autorização permite estender o avaliador por omissão:

```

security {
  authorization {
    pdp = customPolicyDecisionPoint
    inputProvider = DefaultAuthorizationInputProvider
  }
}

```

Listing 5.3: DSL de configuração do *interceptor* de autorização

5.11.4 Interceptor de Rate Limiting

O `RateLimitInterceptor` aplica limites de utilização antes da chamada ao fornecedor. Numa **AI Gateway**, este mecanismo tem dois objetivos principais: proteger o sistema contra abuso ou tráfego excessivo e controlar custos associados a chamadas de inferência. A limitação de taxa é uma estratégia comum para impor um teto de ações repetidas num intervalo temporal, reduzindo abuso de APIs, força bruta e carga excessiva [57].

A importância deste *interceptor* é maior do que numa API tradicional, porque cada pedido pode representar custo financeiro direto, consumo de quotas externas e ocupação prolongada de ligações em *streaming*. Sem *rate limiting*, um cliente mal configurado, uma automação em ciclo ou um utilizador abusivo pode saturar a **Gateway**, esgotar quotas nos fornecedores e degradar o serviço para clientes legítimos. O *interceptor* permite aplicar justiça operacional: cada cliente, plano, modelo ou fornecedor pode ter limites próprios.

A lógica é orientada por políticas. Cada `RateLimitPolicy` extrai dados do `GatewayContext` e devolve `RateLimitTarget`. Um *target* contém uma chave, como cliente/modelo/plano, e uma `RateLimitDefinition`, composta por limite, tipo e janela temporal. Isto permite políticas diferentes por cliente, plano, modelo ou fornecedor.

O store atual em memória usa buckets protegidos por `Mutex`. Quando um pedido chega, o *interceptor* tenta consumir uma unidade em todos os buckets aplicáveis. Se todos permitirem consumo, a cadeia continua. Se algum limite estiver esgotado, devolve `TooManyRequestsError` com `retryAfter`. Esta resposta permite que clientes bem comportados reduzam ritmo em vez de insistirem. Para desenvolvimento e instância única, este modelo é suficiente; em escalamento horizontal, o contrato `RateLimitStore` permite substituir a implementação por **Redis** ou outro *backend* partilhado. Essa substituição é necessária quando várias instâncias da **Gateway** devem partilhar a mesma visão de quota.

A configuração deste mecanismo recorre ao seguinte bloco:

```
interceptors {
  rateLimiting {
    store = InMemoryRateLimitStore()
    addPolicy(rateLimitPolicy)
  }
}
```

Listing 5.4: DSL de configuração do *interceptor* de *rate limiting*

5.11.5 Interceptor de Circuit Breaker

O `CircuitBreakerInterceptor` protege a **Gateway** contra chamadas repetidas a um *outbound* em falha. O padrão de *circuit breaker* é usado para lidar com falhas em serviços remotos, evitando insistir numa dependência que está indisponível e dando tempo para recuperação [58–60]. Numa **Gateway** de IA, esta proteção é especialmente útil porque fornecedores externos podem falhar por indisponibilidade, *timeouts*, quotas ou erros 5xx.

A alternativa simples seria repetir pedidos até obter sucesso. Essa abordagem é perigosa

quando o fornecedor está realmente indisponível: as tentativas acumulam latência, ocupam threads ou corrotinas, aumentam custos e podem agravar a falha no serviço externo. O *circuit breaker* foi criado para evitar esse comportamento. Quando a falha ultrapassa um limiar, o circuito abre e a **Gateway** passa a falhar rapidamente aquele destino, libertando recursos e permitindo que mecanismos como *fallback* escolham outro *outbound*.

Para cada combinação de fornecedor/modelo, o *interceptor* identifica o `outbound.key` e consulta o `CircuitBreakerStore`. Se o circuito estiver `OPEN`, o pedido falha rapidamente com `ApiDownError` e o *outbound* é acrescentado ao conjunto de *outbounds* negados no contexto. Esta falha rápida reduz latência, evita consumo de recursos e dá ao *fallback* informação para não tentar novamente o mesmo destino.

Quando a chamada prossegue, o *interceptor* observa o resultado. Erros incrementam o contador de falhas; ao atingir `failureThreshold`, o circuito passa para `OPEN`. Após um período de recuperação, o estado `HALF_OPEN` permite testar um número limitado de pedidos antes de voltar ao estado `CLOSED`, evitando inundar um fornecedor que ainda está a recuperar [58]. A configuração inclui `failureThreshold`, `resetTimeoutMs` e `halfOpenTestRequests`. A implementação atual cobre a abertura e fecho básico do circuito; a evolução temporal mais completa do estado `HALF_OPEN` é uma melhoria natural.

```
interceptors {
  circuitBreaker {
    store = InMemoryCircuitBreakerStore()
    config = CircuitBreakerConfig(
      failureThreshold = 5,
      resetTimeoutMs = 10000L,
      halfOpenTestRequests = 2
    )
  }
}
```

Listing 5.5: DSL de configuração do *interceptor* de *circuit breaker*

5.11.6 Interceptor de Fallback

O `FallbackInterceptor` permite tentar alternativas quando a chamada principal falha. Em sistemas de IA, *fallback* ao nível de modelo ou fornecedor é relevante porque falhas nas APIs de inferência fornecidas pelas LLMs são um cenário frequente em produção: rate limits, indisponibilidade, quotas, *timeouts* ou modelos descontinuados podem impedir a resposta do fornecedor principal [61,62]. Um *gateway* é o ponto certo para esta política, porque conhece os *outbounds* configurados e consegue trocar de destino sem exigir alterações no cliente.

A decisão de colocar *fallback* na **Gateway**, e não nos clientes, reduz duplicação e melhora controlo operacional. Se cada aplicação cliente implementasse a sua própria lógica de *fallback*, seria necessário repetir regras de prioridade, tratamento de erros, mapeamento de contratos e métricas em vários pontos. Ao centralizar a política, o **SDK** consegue manter o mesmo contrato de entrada e decidir internamente que fornecedor ou modelo alternativo deve ser tentado. Isto é

particularmente útil quando o cliente usa um contrato compatível com **Anthropic** ou **OpenAI**, mas a **Gateway** pode executar a chamada noutro *provider* configurado.

A implementação atual usa a lista de *outbounds* disponíveis. Primeiro tenta o *outbound* correspondente ao fornecedor e modelo pedidos; se falhar, acrescenta esse *outbound* ao conjunto de negados e tenta alternativas. Para cada tentativa, cria um novo **GatewayContext** com os mesmos atributos, mas com **provider** e **model** atualizados para o *outbound* alternativo.

A integração com o *circuit breaker* é feita através do conjunto partilhado de *outbounds* negados. Assim, se um circuito estiver aberto, o *fallback* evita esse destino e tenta outro modelo ou fornecedor. Este desenho permite construir políticas de resiliência como “tentar **Gemini**, depois **OpenAI**-compatible via **Groq**, depois **Anthropic**”, mantendo a lógica de tentativa fora dos *adapters*. Também permite distinguir degradação controlada de erro total: a resposta pode chegar por um modelo alternativo, enquanto métricas e *tracing* registam que ocorreu *fallback*.

A evolução futura poderá acrescentar prioridades configuráveis, condições por código de erro, orçamentos de tentativa e métricas específicas de *fallback*. Estas regras são importantes porque nem todo erro justifica *fallback*: erros de autenticação ou autorização devem falhar imediatamente, enquanto *timeouts*, 429 e 5xx podem justificar uma alternativa.

A sua ativação é extremamente simples, não requerendo configuração intrincada:

```
interceptors {  
    fallback()  
}
```

Listing 5.6: DSL de configuração do *interceptor* de *fallback*

5.11.7 Interceptor de Logging e Tracing

O **RequestLoggingInterceptor** regista fornecedor, modelo, sucesso, erro e conclusão de streams através da abstração **GatewayLogger**. No *target JVM* pode ser ligado a **SLF4J**; no *target JavaScript* pode usar consola ou outra integração. O objetivo é garantir visibilidade mínima mesmo quando a telemetria completa não está ativa.

O *logging* foi mantido separado das métricas porque responde a perguntas diferentes. Métricas mostram tendências agregadas, como latência média ou número de erros; *logs* ajudam a explicar um pedido concreto. Numa **Gateway** de IA, esta distinção também tem impacto de privacidade: o objetivo é registar metadados operacionais, e não despejar *prompts*, respostas completas ou *tokens* sensíveis nos *logs*.

O **TracingInterceptor** envolve o pedido num *span* chamado **gateway.request.process**. Quando combinado com **OpenTelemetry**, este *span* permite correlacionar latência, erros, chamadas externas e métricas agregadas. Em cenários de *fallback* ou *circuit breaker*, *tracing* é particularmente útil porque permite observar o percurso real do pedido e distinguir falhas do fornecedor, decisões da **Gateway** e erros de cliente. Também permite perceber se uma resposta lenta resulta do fornecedor principal, de uma tentativa alternativa, de validação de token ou de uma política interna.

A instalação processa-se em dois blocos da DSL, um explícito e outro decorrente da configuração de métricas:

```

interceptors {
    // Instalacao manual do Logging Interceptor
    use(RequestLoggingInterceptor(logger))

    // O TracingInterceptor e instalado automaticamente ao fornecer o tracer as metricas
    metrics {
        tracer = telemetryRuntime.tracer
    }
}

```

Listing 5.7: Instalação dos *interceptors* de *logging* e *tracing*

5.11.8 MCP Broker e Ferramentas Externas

O **MCP Broker** surge como uma extensão natural da **Gateway**: deixar de a tratar apenas como um ponto de entrada para inferência e aproximá-la de uma *gateway* de IA mais completa. A inferência continua a ser uma parte central do sistema, mas não esgota o problema. Em muitos cenários, um modelo só consegue produzir uma resposta útil se puder consultar recursos externos, chamar ferramentas, obter contexto adicional ou executar ações controladas. É nesse espaço que entra o **Model Context Protocol (MCP)**.

O objetivo do Broker é oferecer um ponto central para registar, descrever e expor ferramentas de forma consistente. Em vez de cada aplicação repetir a mesma configuração de ferramentas, *schemas*, permissões e transportes, a **Gateway** poderá concentrar essa informação e disponibilizá-la aos modelos através de uma interface comum. Assim, o sistema deixa de encaminhar apenas pedidos de geração de texto e passa também a organizar o acesso a capacidades externas, como operações sobre sistemas internos, consulta de recursos, execução de comandos controlados ou reutilização de *prompts* padronizados.

O módulo `mcp-broker` ainda se encontra numa fase inicial de implementação e assenta na biblioteca `io.modelcontextprotocol:kotlin-sdk`. A direção técnica prevista passa por suportar o registo de ferramentas, recursos e *prompts*, bem como a geração de esquemas JSON e a configuração de transportes como *stdio*, **SSE** e **WebSocket**. A médio prazo, a intenção é permitir configuração declarativa, por exemplo através de ficheiros **YAML**, para que um utilizador consiga expor novas ferramentas sem alterar código aplicacional em cada integração.

Para perceber a utilidade do Broker, é importante observar o ciclo de *tool calling*, ilustrado na Figura 5.8. Neste fluxo, o cliente apresenta ao modelo as ferramentas disponíveis e os respetivos *schemas*. Se o modelo precisar de usar uma dessas ferramentas, não responde imediatamente ao utilizador; em vez disso, devolve uma chamada estruturada com o nome da função e os argumentos. A aplicação executa essa chamada, devolve o resultado ao modelo, e só então o modelo produz a resposta final com base no novo contexto.




Figura 5.8: Visão geral do fluxo de *Tool Calling* [12].

Neste desenho, o **MCP Broker** não é mais um *adapter* de inferência. É uma peça complementar, focada em tornar ferramentas externas descobríveis, reutilizáveis e controladas a partir de um ponto central. Quando estiver concluído, permitirá que a **Gateway/SDK** atue como uma infraestrutura de IA mais abrangente: recebe pedidos, encaminha inferência, aplica políticas transversais e também expõe capacidades externas através de **MCP**. Esta parte ainda está em desenvolvimento, pelo que a secção representa a direção arquitetural pretendida e o papel que o Broker deverá assumir na versão final.

5.12 Distribuição Multiplataforma

Um dos objetivos do **OmniAI SDK** é permitir que a lógica central da abstração de modelos seja reutilizada em diferentes ambientes de execução. O ecossistema **Kotlin Multiplatform** permite separar o código agnóstico das implementações específicas: o domínio, os contratos, as portas, os adaptadores principais, a DSL e parte dos *interceptors* residem em *source sets* comuns; por sua vez, os detalhes de infraestrutura como o cliente **HTTP**, a reflexão de prioridades, a integração com o servidor **Ktor** e as pontes de plataforma ficam isolados em *source sets* específicos.

No *target JVM*, o **OmniAI SDK** pode ser consumido nativamente por aplicações **Kotlin** ou Java. Este é o ambiente mais maduro no estado atual do projeto, sendo a fundação sobre a qual a nossa instância de demonstração (POC) do **OmniAI Gateway** foi construída. A implementação **JVM** inclui o cliente **HTTP Ktor**, a integração nativa com o servidor **Ktor**, a autenticação baseada em descoberta **OIDC**, a telemetria e a execução real dos *outbounds*. A futura distribuição via **Maven** permitirá que qualquer aplicação adicione o **SDK** como uma

dependência versionada clássica, eliminando a necessidade de recorrer a *composite builds*.

Relativamente ao *target* **JavaScript/Node.js**, o projeto prepara a disponibilização de uma API consumível a partir do ecossistema **TypeScript**. A utilização da anotação **@JsExport** atua como uma fachada que encapsula a configuração em tipos exportáveis, garantindo que as estruturas internas do **Kotlin** não transbordam de forma inadequada para a fronteira JS. Esta camada estabelece as fundações para o consumo via **NPM**, embora ainda não apresente paridade total de funcionalidades com o ambiente **JVM**.

A principal premissa desta arquitetura multiplataforma é a de que nem todos os componentes devem ser partilhados. Enquanto o domínio e os contratos devem permanecer estritamente comuns e agnósticos, as camadas de transporte **HTTP**, servidor, observabilidade e segurança podem e devem ter implementações otimizadas para cada plataforma. Esta fronteira arquitetural evita a duplicação de código sem forçar uma abstração demasiado rígida ou ineficiente. A linha de evolução natural passa por consolidar a API pública do **OmniAI SDK**, estabilizar o versionamento semântico, automatizar a publicação **Maven/NPM** através de *Continuous Delivery* (CD) e documentar exemplos mínimos de consumo para a **JVM** e **Node.js**.

Capítulo 6

Proof of Concepts e Validação

6.1 Validação do *Proof of Concept* da OmniAI Gateway

A validação principal da arquitetura foi efetuada através da aplicação **OmniAiGateway**, nomeadamente a instanciação de uma **OmniAiGateway** como um *Proof of Concept* (PoC) que integra o **OmniAI SDK** via *composite build*, conforme detalhado anteriormente. Esta aplicação é responsável por carregar o ficheiro de configuração `application.conf`, resolver as variáveis de ambiente necessárias, instanciar o `KtorHttpClient` e configurar os respetivos *outbounds*. Adicionalmente, assegura a ativação dos módulos de segurança e telemetria, a inicialização do *runtime* do *Software Development Kit* e a exposição de *endpoints HTTP* compatíveis com as APIs da **OpenAI** [1], **Anthropic** [2] e **Gemini** [3].

É importante clarificar que o comportamento validado não configura um mecanismo de "roteamento inteligente". A implementação atual baseia-se numa seleção direta por configuração, em que o pedido original já especifica o fornecedor e o modelo pretendidos, cabendo ao *dispatcher* padrão direcionar o fluxo para o *outbound* correspondente. Embora este desenho garanta o desacoplamento efetivo entre o cliente e o fornecedor, a seleção dinâmica por critérios como custo, latência, qualidade ou plano de subscrição ainda não está implementada. Contudo, os mecanismos de *fallback* e *circuit breaker* [60] [59] [58] já existentes estabelecem a infraestrutura necessária para evoluir a solução em direção a um roteamento semântico ou otimizado no futuro.




Figura 6.1: Cenários de validação do *Proof of Concept*

6.2 Validação com REST Client

O ficheiro `gateway-requests.http` foi utilizado para a validação manual dos *endpoints* expostos pela **OmniAI Gateway**. Este ficheiro agrupa pedidos direcionados a `/v1/chat/completions`, `/v1/messages` e `/v1beta/models/model:generateContent`, cobrindo cenários de respostas unárias, *streaming*, geração baseada em parâmetros e integração com autenticação via token Bearer.

A relevância deste cenário de testes fundamenta-se em dois pilares principais. Em primeiro lugar, viabilizou a validação rigorosa dos contratos **HTTP** recebidos pela **OmniAI Gateway**, prescindindo do acoplamento a aplicações externas. Em segundo lugar, proporcionou a testagem rápida e integral do fluxo de dados: desde a emissão do token pelo **Logto** e a respetiva autenticação do pedido, passando pela tradução *inbound*, conversão para o *outbound* e invocação do fornecedor configurado, até à devolução da resposta no formato esperado pelo cliente.

6.3 Validação de Segurança com Logto

A camada de segurança foi validada com **Logto** como *Authorization Server* local. O ambiente **Docker** inclui **Logto** [39], **PostgreSQL** [40], **OpenTelemetry Collector** [45], **Prometheus** [42] e **Grafana** [43]. A configuração do *Proof of Concept* usa **OIDC** Discovery [63] para obter metadados do servidor de autorização e validar *tokens* com audiência configurada para o recurso da API.

Durante o desenvolvimento foram realizados testes exploratórios com **Keycloak** [54], mas a configuração final mudou para **Logto** [39] por reduzir a complexidade operacional. O **Logto** facilitou a criação de API Resources, aplicações *Machine-to-Machine* e fluxos **OIDC** adequados à validação da **OmniAI Gateway** como *Resource Server* [64].

O fluxo também foi validado com `run_claude.py`. Este script abre o *browser* para autenticação no **Logto**, usa **PKCE** [65], troca o código por um token e inicia o **Claude Code** com `ANTHROPIC_BASE_URL` a apontar para a **OmniAI Gateway**. O cabeçalho `Authorization` é injetado através de `ANTHROPIC_CUSTOM_HEADERS`, permitindo testar um cliente real compatível

com **Anthropic** a passar pela nossa **Gateway**.

6.4 Validação de Observabilidade

A observabilidade foi validada com **OpenTelemetry Collector**, **Prometheus** e **Grafana**. A **OmniAiGateway** ativa métricas na DSL do **OmniAI SDK**, incluindo latência padrão, contagem de *tokens* e contagem de erros. Também acrescenta atributos como IP do cliente, versão do **OmniAI SDK**, audiência e dados derivados do resultado de autenticação, como `sub`, `email` ou `preferred_username` quando disponíveis.

O objetivo desta validação foi confirmar que a **OmniAI Gateway** consegue produzir telemetria e garantir observabilidade em tempo real durante o processamento de pedidos. A utilização de **Prometheus** [42] e **Grafana** [43] permitiu monitorizar as métricas operacionais da aplicação, comprovando que o módulo de telemetria corre de forma isolada da lógica de inferência sendo definido via DSL e exposto por *adapters* dedicados.

6.5 Validação com Aplicações Cliente

Para validar a compatibilidade da **OmniAI Gateway** com aplicações existentes, foram estudados e testados clientes que permitem configurar *endpoints* alternativos para APIs de inferência. Esta capacidade é particularmente relevante porque permite introduzir a **Gateway** numa aplicação já existente sem necessidade de modificar a sua lógica interna.

Um dos casos analisados foi o **Claude Code**, que disponibiliza a variável de ambiente `ANTHROPIC_BASE_URL` para redefinir o *endpoint* utilizado nos pedidos à API da **Anthropic**. Para complementar esta validação, foi também desenvolvido um teste utilizando o **SDK** oficial da **Anthropic**, implementado em `node-tests/anthropicSDKTest.js`. Neste cenário, o cliente foi configurado com um `baseUrl` local e uma chave fictícia, demonstrando que aplicações construídas sobre o **SDK** conseguem comunicar com a **OmniAI Gateway** quando esta expõe um contrato compatível com a API original.

6.5.1 Execução do Claude Code com autenticação Logto

Para além dos testes realizados através de pedidos diretos e do **SDK** oficial, foi desenvolvido o script `run_claude.py` com o objetivo de validar um cenário de utilização mais próximo de um ambiente real. Este script automatiza a configuração necessária para que o **Claude Code** utilize a **OmniAI Gateway** como ponto de entrada para os pedidos de inferência, sem qualquer alteração ao código do cliente.

O processo inicia-se com a autenticação através do **Logto**. Durante a execução, o script gera os parâmetros necessários para o fluxo **PKCE**, abre o navegador para o processo de autenticação **OIDC** e disponibiliza temporariamente um servidor **HTTP** local em `localhost:8080` para receber o código de autorização devolvido pelo fornecedor de identidade. Após a autenticação do utilizador, o código obtido é trocado por um *access token* associado ao recurso da API configurado no **Logto**.

Concluída a autenticação, o script prepara automaticamente o ambiente de execução do **Claude Code**. Para tal, define uma chave fictícia em `ANTHROPIC_API_KEY`, configura a variável `ANTHROPIC_BASE_URL` para apontar para a instância local da **Gateway** e injeta o *access token* obtido através do cabeçalho `Authorization`, utilizando a variável `ANTHROPIC_CUSTOM_HEADERS`. Finalmente, o comando `claude` é iniciado já com toda a configuração necessária.

Esta validação permitiu demonstrar que uma aplicação desenvolvida para comunicar com a API da **Anthropic** pode ser integrada com a **OmniAI Gateway** apenas através de configuração. O cenário exercita simultaneamente a autenticação federada através do **Logto**, a validação de *tokens* na **Gateway** e o encaminhamento dos pedidos para os fornecedores configurados, constituindo assim uma validação de ponta a ponta da arquitetura proposta.

Para além do **Claude Code**, foram ainda analisadas plataformas como *OpenCode* [66], *LibreChat* [67] e *Diffy* [68], uma vez que também suportam a configuração de *endpoints* compatíveis com APIs existentes. Estes casos reforçam uma das principais vantagens da arquitetura proposta: quando uma aplicação já utiliza um contrato amplamente adotado, a introdução da **OmniAI Gateway** pode ser realizada através de configuração, evitando alterações na lógica da aplicação cliente e reduzindo significativamente o esforço de integração.

6.6 Limites da Validação

A validação realizada confirma o consumo do **OmniAI SDK** pelo Proof of Concept, a exposição **HTTP** com **Ktor**, a integração com **Logto**, o uso de **Prometheus/Grafana** e a compatibilidade com clientes reais ou semi-reais. No entanto, existem limites importantes. O Proof of Concept ainda não demonstra invocação de ferramentas via **MCP Broker**, nem políticas avançadas de roteamento por custo, latência ou qualidade. Estes pontos dependem de trabalho futuro sobre o módulo `mcp-broker`, sobre políticas de *dispatcher* e sobre *stores* distribuídos para cenários multi-instância.

Capítulo 7

Conclusões e Trabalho Futuro

7.1 Conclusões

O trabalho desenvolvido permitiu concretizar o **OmniAI SDK** como uma base reutilizável para a instanciação de *gateways* de IA em **Kotlin Multiplatform**. A solução estabilizou um domínio comum para pedidos, respostas, eventos de *streaming* e ferramentas, suportado por contratos específicos para **OpenAI** [1], **Anthropic** [2] e **Gemini** [3]. Através dos *inbound adapters*, dos *outbound adapters* e do **DispatcherPort**, foi possível normalizar fluxos que, nas APIs originais, apresentam estruturas JSON, ciclos **SSE** e modelos de *tool calling* distintos, mantendo a lógica central desacoplada dos detalhes de cada um dos fornecedores.

A separação entre **OmniAI SDK** e **OmniAI Gateway** revelou-se uma decisão estrutural importante. O **OmniAI SDK** concentra o domínio, as portas, os tradutores, a *pipeline* e a DSL de configuração enquanto que a **OmniAI Gateway** desenvolvida neste projeto funciona como uma instância concreta dessa infraestrutura, construída sobre **Ktor** no *target JVM*. O *Proof of Concept* validou a montagem de *outbounds* configuráveis, a exposição de contratos compatíveis com clientes existentes, a integração com **Logto** [39] via **OIDC** [63], a recolha de telemetria com **OpenTelemetry** [45], **Prometheus** [42] e **Grafana** [43], e a aplicação de *interceptors* para autenticação, autorização, métricas, *rate limiting*, *circuit breaker*, *fallback*, *logging* e *tracing*.

Um dos principais desafios foi lidar com as diferenças reais entre os fornecedores sem reduzir a abstração a uma equivalência superficial de campos. **OpenAI**, **Anthropic** e **Gemini** convergem em conceitos como mensagens, papéis, ferramentas e consumo de *tokens*, mas divergem na forma como organizam o histórico, representam chamadas de ferramentas, ativam *streaming* e emitem eventos. No caso da **Gemini**, as restrições sobre *schemas* e o uso de estruturas próprias, como **functionDeclarations**, **generationConfig** e eventos parciais com formato de resposta completa, exigiram um tratamento específico. De forma semelhante, a fragmentação dos eventos **SSE** obrigou à criação de um modelo comum de eventos capaz de preservar deltas de texto, argumentos parciais de ferramentas, utilização de *tokens* e estados de conclusão.

Apesar destes resultados, o projeto não deve ser lido como uma solução finalizada para todos os cenários de produção. A validação demonstrou uma base estável do **OmniAI SDK** e da **OmniAI Gateway** como *Proof of Concept* na **JVM**, mas identificou pontos que dependem de continuação. O **MCP Broker** deve evoluir de uma fundação inicial para um componente operacional, com carregamento declarativo de ferramentas, recursos e *prompts* através de **YAML**,

registro efetivo de *handlers* e suporte robusto a *stdio*, **SSE** e **WebSocket**. Será também necessário completar a paridade do *target* **JavaScript/Node.js**, consolidar a API exportada e preparar a publicação do **SDK** em **Maven** e **NPM** com versionamento semântico e documentação de consumo.

O balanço final é positivo e realista. A arquitetura construída reduz o acoplamento entre aplicações cliente e fornecedores de LLMs, centraliza preocupações operacionais que normalmente ficam dispersas e oferece uma base extensível para integrações futuras. Para além do resultado técnico, o desenvolvimento em dupla permitiu transformar um problema inicialmente amplo num conjunto de decisões arquiteturais justificadas, implementadas e validadas. Esse processo foi uma parte essencial da aprendizagem alcançada no projeto, tanto ao nível da engenharia de software como da compreensão prática das limitações atuais das APIs de inferência.

7.2 Melhorias Futuras e Escalabilidade

Como trabalho futuro, existem várias linhas de evolução. A primeira é consolidar a distribuição pública do **SDK** via **Maven** e **NPM**, garantindo documentação de instalação, versionamento semântico e exemplos de consumo. A segunda é completar a paridade entre *targets* **JVM** e **JavaScript**, sobretudo na montagem de *runtime* e transporte **HTTP**.

Outra melhoria importante é aprofundar o **MCP Broker**, incluindo carregamento efetivo de ferramentas via **YAML**, execução completa dos *handlers* **MCP** e suporte robusto a **SSE** e **WebSocket**. Também será relevante melhorar as políticas de roteamento, permitindo decisões com base em custo, latência, disponibilidade, qualidade do modelo, plano do cliente e limites de utilização.

Por fim, a camada de segurança pode evoluir para políticas de autorização mais expressivas, integração com PDPs externos, introspeção real de *tokens* opacos e mapeamento mais fino entre *claims*, planos e quotas. Estas melhorias permitiriam aproximar a **OmniAI Gateway** de uma solução pronta para ambientes *multi-tenant* e produção.

Apêndice A

Exemplos JSON das APIs de Inferência

Este apêndice reúne os exemplos completos dos corpos JSON utilizados durante o estudo das APIs de inferência. Os exemplos incluem pedidos e respostas de geração de texto, chamadas de ferramentas (*tool calling*), *streaming* e configuração de raciocínio (*thinking*), permitindo ao leitor consultar as estruturas integrais que foram analisadas e comparadas no Capítulo 2.

A.1 Pedidos (*Requests*)

A.1.1 OpenAI (formato compatível)

```
{
  "model": "llama3.2:1b",
  "messages": [
    {
      "role": "system",
      "content": "Es um assistente local a correr em Docker."
    },
    {
      "role": "user",
      "content": "Ola! Estas a funcionar?"
    }
  ],
  "temperature": 0.7
}
```

Listing A.1: Pedido básico à API da **OpenAI** (geração com *system prompt*)

```

{
  "model": "llama3.2:1b",
  "messages": [
    {
      "role": "user",
      "content": "Como esta o preco das acoes da Apple (AAPL)?"
    }
  ],
  "tools": [
    {
      "type": "function",
      "function": {
        "name": "get_stock_price",
        "description": "Obtem o preco atual de uma acao",
        "parameters": {
          "type": "object",
          "properties": {
            "symbol": {
              "type": "string",
              "description": "O ticker da empresa, ex: AAPL"
            }
          }
        },
        "required": ["symbol"]
      }
    }
  ],
  "tool_choice": "auto"
}

```

Listing A.2: Pedido à API da **OpenAI** com ferramentas (*tool calling*)

```
{
  "model": "llama-3.3-70b-versatile",
  "messages": [
    {
      "role": "system",
      "content": "Es um assistente tecnico que responde apenas em topicos."
    },
    {
      "role": "user",
      "content": "Explica a diferenca entre CPU e GPU."
    }
  ],
  "temperature": 0.5,
  "max_tokens": 1024,
  "top_p": 1,
  "stream": false,
  "stop": ["FIM", "TERMINAR"],
  "presence_penalty": 0.0,
  "frequency_penalty": 0.0,
  "seed": 42,
  "user": "utilizador_123",
  "response_format": { "type": "text" },
  "logit_bias": null
}
```

Listing A.3: Pedido à API da **OpenAI** com todos os parâmetros de geração

```
{
  "model": "llama3.2:1b",
  "messages": [
    {
      "role": "user",
      "content": "O que e Kubernetes?"
    }
  ],
  "stream": true
}
```

Listing A.4: Pedido *stream* à API da **OpenAI**

A.1.2 Anthropic


```
{
  "model": "claude-3-5-haiku-20241022",
  "max_tokens": 1024,
  "system": "You are a cat. Your name is Neko.",
  "messages": [
    {
      "role": "user",
      "content": "Hello there"
    }
  ]
}
```

Listing A.5: Pedido básico à API da **Anthropic** (geração com *system prompt*)

```
{
  "model": "claude-3-5-haiku-20241022",
  "max_tokens": 1024,
  "messages": [
    {
      "role": "user",
      "content": "What is the weather like in Lisbon?"
    }
  ],
  "tools": [
    {
      "name": "get_weather",
      "description": "Get the current weather in a given location",
      "input_schema": {
        "type": "object",
        "properties": {
          "location": {
            "type": "string",
            "description": "The city and country, e.g. Lisbon, Portugal"
          }
        }
      },
      "required": ["location"]
    }
  ]
}
```

Listing A.6: Pedido à API da **Anthropic** com ferramentas (*tool calling*)

```
{
  "model": "claude-3-5-haiku-20241022",
  "max_tokens": 1024,
  "temperature": 1.0,
  "top_p": 0.8,
  "top_k": 10,
  "stop_sequences": ["Title"],
  "messages": [
    {
      "role": "user",
      "content": "Explain how AI works"
    }
  ]
}
```

Listing A.7: Pedido à API da **Anthropic** com parâmetros de amostragem

```
{
  "model": "claude-3-7-sonnet-20250219",
  "max_tokens": 4096,
  "thinking": {
    "type": "enabled",
    "budget_tokens": 2048
  },
  "messages": [
    {
      "role": "user",
      "content": "How does AI work?"
    }
  ]
}
```

Listing A.8: Pedido à API da **Anthropic** com raciocínio (*thinking*)

```
{
  "model": "claude-3-5-haiku-20241022",
  "max_tokens": 200,
  "messages": [
    {
      "role": "user",
      "content": "Explain AI."
    }
  ],
  "stream": true
}
```

Listing A.9: Pedido *stream* à API da **Anthropic**

A.1.3 Google Gemini

```
{
  "system_instruction": {
    "parts": [
      { "text": "You are a cat. Your name is Neko." }
    ]
  },
  "contents": [
    {
      "parts": [
        { "text": "Hello there" }
      ]
    }
  ]
}
```

Listing A.10: Pedido básico à API do **Gemini** (geração com *system instruction*)

```

{
  "contents": [
    {
      "role": "user",
      "parts": [
        {
          "text": "Schedule a meeting with Bob for tomorrow."
        }
      ]
    }
  ],
  "tools": [
    {
      "functionDeclarations": [
        {
          "name": "schedule_meeting",
          "description": "Schedules a meeting with attendees.",
          "parameters": {
            "type": "object",
            "properties": {
              "attendees": {
                "type": "array",
                "items": { "type": "string" }
              },
              "date": { "type": "string" },
              "time": { "type": "string" },
              "topic": { "type": "string" }
            },
            "required": ["attendees", "date", "time", "topic"]
          }
        }
      ]
    }
  ]
}

```

Listing A.11: Pedido à API do **Gemini** com ferramentas (*tool calling*)

```

{
  "contents": [
    {
      "parts": [
        { "text": "Explain how AI works" }
      ]
    }
  ],
  "generationConfig": {
    "stopSequences": ["Title"],
    "temperature": 1.0,
    "topP": 0.8,
    "topK": 10,
    "thinkingConfig": {
      "include_thoughts": true,
      "thinkingLevel": "low"
    }
  }
}

```

Listing A.12: Pedido à API do **Gemini** com configuração de geração e *thinking*

```

{
  "contents": [
    {
      "parts": [
        { "text": "Explain how AI works" }
      ]
    }
  ]
}

```

Listing A.13: Pedido *stream* à API do **Gemini** (URI com `?alt=sse`)

A.2 Respostas (*Responses*)

A.2.1 OpenAI (formato compatível)

```

{
  "id": "chatcmpl-31",
  "object": "chat.completion",
  "created": 1773531116,
  "model": "llama3.2:1b",
  "system_fingerprint": "fp_ollama",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "Desculpe, mas posso tentar ajuda-lo!"
      },
      "finish_reason": "stop"
    }
  ],
  "usage": {
    "prompt_tokens": 46,
    "completion_tokens": 40,
    "total_tokens": 86
  }
}

```

Listing A.14: Resposta completa da API da **OpenAI** (geração básica)

```

{
  "id": "chatcmpl-53",
  "object": "chat.completion",
  "created": 1773531604,
  "model": "llama3.2:1b",
  "system_fingerprint": "fp_ollama",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "",
        "tool_calls": [
          {
            "id": "call_9fasug2c",
            "index": 0,
            "type": "function",
            "function": {
              "name": "get_stock_price",
              "arguments": "{\"symbol\":\"AAPL\"}"
            }
          }
        ]
      },
      "finish_reason": "tool_calls"
    }
  ],
  "usage": {
    "prompt_tokens": 171,
    "completion_tokens": 19,
    "total_tokens": 190
  }
}

```

Listing A.15: Resposta da API da **OpenAI** (chamada de ferramenta)

```

data: {"id":"chatcmpl-308","object":"chat.completion.chunk",
      "created":1773532270,"model":"llama3.2:1b",
      "choices":[{"index":0,
        "delta":{"role":"assistant","content":"K"},
        "finish_reason":null}]}

data: {"id":"chatcmpl-308","object":"chat.completion.chunk",
      "created":1773532270,"model":"llama3.2:1b",
      "choices":[{"index":0,
        "delta":{"content":"ubernetes "},
        "finish_reason":null}]}

data: {"id":"chatcmpl-308","object":"chat.completion.chunk",
      "created":1773532272,"model":"llama3.2:1b",
      "choices":[{"index":0,
        "delta":{},
        "finish_reason":"stop"}]}

data: [DONE]

```

Listing A.16: Resposta *stream* da **OpenAI** (eventos **SSE**)

A.2.2 Anthropic

```

{
  "id": "msg_01Xf...",
  "type": "message",
  "role": "assistant",
  "model": "claude-3-5-haiku-20241022",
  "content": [
    {
      "type": "text",
      "text": "Artificial intelligence (AI) is a complex field..."
    }
  ],
  "stop_reason": "end_turn",
  "usage": {
    "input_tokens": 14,
    "output_tokens": 350
  }
}

```

Listing A.17: Resposta completa da API da **Anthropic** (geração básica)


```

{
  "id": "msg_01Cd...",
  "type": "message",
  "role": "assistant",
  "content": [
    {
      "type": "text",
      "text": "I can help you check the weather in Lisbon."
    },
    {
      "type": "tool_use",
      "id": "toolu_01A02B03C",
      "name": "get_weather",
      "input": { "location": "Lisbon, Portugal" }
    }
  ],
  "stop_reason": "tool_use"
}

```

Listing A.18: Resposta da API da **Anthropic** (chamada de ferramenta)

```

{
  "id": "msg_01xyz...",
  "type": "message",
  "role": "assistant",
  "model": "claude-3-7-sonnet-20250219",
  "content": [
    {
      "type": "thinking",
      "thinking": "Here I need to explain how AI works...",
      "signature": "zxcvbnm1234567890..."
    },
    {
      "type": "text",
      "text": "Artificial Intelligence (AI) works fundamentally by..."
    }
  ],
  "stop_reason": "end_turn",
  "stop_sequence": null,
  "usage": {
    "input_tokens": 13,
    "output_tokens": 850
  }
}

```

Listing A.19: Resposta da API da **Anthropic** (raciocínio *thinking*)

```

event: message_start
data: {"type": "message_start",
      "message": {"id": "msg_d6d...", "role": "assistant",
                  "model": "claude-3-5-haiku-20241022"}}

event: content_block_start
data: {"type": "content_block_start", "index": 0,
      "content_block": {"type": "text"}}

event: content_block_delta
data: {"type": "content_block_delta", "index": 0,
      "delta": {"type": "text_delta", "text": "Artificial"}}

event: content_block_delta
data: {"type": "content_block_delta", "index": 0,
      "delta": {"type": "text_delta", "text": " intelligence"}}

event: content_block_stop
data: {"type": "content_block_stop", "index": 0}

event: message_stop
data: {"type": "message_stop"}

```

Listing A.20: Resposta *stream* da **Anthropic** (eventos **SSE**)

```

{
  "role": "user",
  "content": [
    {
      "type": "tool_result",
      "tool_use_id": "toolu_01A02B03C",
      "content": "The weather is 18C and sunny."
    }
  ]
}

```

Listing A.21: Devolução de resultado de ferramenta na API da **Anthropic**

A.2.3 Google Gemini

```

{
  "candidates": [
    {
      "content": {
        "parts": [
          {
            "text": "At its simplest level, AI works by...",
            "thoughtSignature": "..."
          }
        ],
        "role": "model"
      },
      "finishReason": "STOP",
      "index": 0
    }
  ],
  "usageMetadata": {
    "promptTokenCount": 5,
    "candidatesTokenCount": 969,
    "totalTokenCount": 1480,
    "promptTokensDetails": [
      { "modality": "TEXT", "tokenCount": 5 }
    ],
    "thoughtsTokenCount": 506
  },
  "modelVersion": "gemini-3-flash-preview",
  "responseId": "feKyafqAEJ_VvdIP5s7TSA"
}

```

Listing A.22: Resposta completa da API do **Gemini** (geração básica)

```

{
  "candidates": [
    {
      "content": {
        "parts": [
          {
            "functionCall": {
              "name": "schedule_meeting",
              "args": {
                "time": "10:00",
                "date": "2025-03-27",
                "attendees": ["Bob", "Alice"],
                "topic": "Q3 planning"
              },
              "id": "fcaog9xf"
            },
            "thoughtSignature": "..."
          }
        ],
        "role": "model"
      },
      "finishReason": "STOP",
      "index": 0,
      "finishMessage": "Model generated function call(s).",
    }
  ],
  "usageMetadata": {
    "promptTokenCount": 203,
    "candidatesTokenCount": 54,
    "totalTokenCount": 423,
    "promptTokensDetails": [
      { "modality": "TEXT", "tokenCount": 203 }
    ],
    "thoughtsTokenCount": 166
  },
  "modelVersion": "gemini-3-flash-preview",
  "responseId": "AueyadTFGvKlvdIPrv74QA"
}

```

Listing A.23: Resposta da API do **Gemini** (chamada de ferramenta)

```

data: {"candidates": [
  {"content": {"parts": [
    {"text": "AI works by "}
  ], "role": "model"}, "index": 0}
], "usageMetadata": {
  "promptTokenCount": 4,
  "candidatesTokenCount": 25,
  "totalTokenCount": 608,
  "thoughtsTokenCount": 579
}, "modelVersion": "gemini-3-flash-preview"}

data: {"candidates": [
  {"content": {"parts": [
    {"text": "processing data."}
  ], "role": "model"}, "index": 0}
], "usageMetadata": {
  "promptTokenCount": 4,
  "candidatesTokenCount": 51,
  "totalTokenCount": 634,
  "thoughtsTokenCount": 579
}, "modelVersion": "gemini-3-flash-preview"}

data: {"candidates": [
  {"content": {"parts": [
    {"text": "", "thoughtSignature": "..."}
  ], "role": "model"},
  "finishReason": "STOP", "index": 0}
], "usageMetadata": {
  "promptTokenCount": 4,
  "candidatesTokenCount": 853,
  "totalTokenCount": 1436,
  "thoughtsTokenCount": 579
}, "modelVersion": "gemini-3-flash-preview"}

```

Listing A.24: Resposta *stream* do **Gemini** (padrão **SSE**)

Apêndice B

Histórico de Planeamento e Riscos

Durante a fase de planeamento foram identificados riscos técnicos e operacionais que continuam relevantes para a evolução do projeto.

B.1 Riscos

Durante o desenvolvimento do projeto foram identificados vários riscos técnicos e operacionais. Estes riscos influenciaram decisões de desenho, prioridades de implementação e estratégias de validação.

- **Curva de aprendizagem tecnológica:** O projeto exigiu a utilização de tecnologias e conceitos com elevada complexidade, nomeadamente **Kotlin Multiplatform**, arquitetura hexagonal, APIs de inferência de diferentes fornecedores, autenticação baseada em **OIDC/OAuth2** e o **Model Context Protocol**. Esta diversidade tecnológica representou um risco inicial, porque aumentou o tempo necessário para compreender os contratos externos, configurar o ambiente de desenvolvimento e definir uma arquitetura estável. A mitigação passou pela realização de protótipos incrementais, pelo estudo isolado das APIs de **OpenAI**, **Anthropic** e **Gemini**, e pela separação progressiva do sistema em módulos com responsabilidades claras.
- **Instabilidade de serviços externos:** A **Gateway** depende de serviços de terceiros, como APIs de inferência, servidores de autorização e ferramentas externas. Estes serviços podem apresentar indisponibilidade temporária, alterações nos contratos, limites de utilização ou comportamentos diferentes dos documentados. Este risco poderia comprometer a validação da solução e tornar os testes dependentes de fatores externos. Para reduzir este impacto, foram usados testes locais, servidores simulados, *mocks* e abstrações sobre o transporte **HTTP**. Além disso, a arquitetura inclui mecanismos de resiliência, como *fallback* e *circuit breaker*, que permitem lidar melhor com falhas de fornecedores.
- **Custos de utilização:** A execução de testes com modelos pagos pode gerar custos inesperados, especialmente em cenários de *streaming*, chamadas repetidas ou testes de integração. Este risco é relevante porque a **Gateway** incentiva a experimentação com múltiplos fornecedores e modelos. A mitigação passou por limitar o número de chamadas reais, utilizar

fornecedores com quotas gratuitas sempre que possível, recorrer a testes locais e validar grande parte da lógica através de contratos, *adapters* e servidores simulados.

- **Complexidade de normalização entre fornecedores:** As APIs de **OpenAI**, **Anthropic** e **Gemini** partilham conceitos semelhantes, como mensagens, modelos, parâmetros de geração e ferramentas, mas representam esses conceitos de formas diferentes. Alguns elementos, como *tool calling*, *streaming*, multimodalidade e metadados específicos, não têm correspondência direta entre fornecedores. Este risco poderia levar a uma abstração demasiado rígida ou à perda de informação específica de cada API. Para o mitigar, foi definido um domínio comum extensível, complementado por campos de opções específicas do fornecedor. Desta forma, o **SDK** consegue representar o núcleo comum sem impedir a passagem de características particulares de cada API.
- **Segurança e dados sensíveis:** A centralização dos pedidos numa **Gateway** aumenta a responsabilidade sobre autenticação, autorização, gestão de *tokens*, *logs*, métricas e chaves de API. Um erro nesta camada poderia expor dados sensíveis ou permitir acesso indevido a modelos e recursos. A mitigação passou pela introdução de uma *pipeline* de segurança com autenticação e autorização separadas, validação de *tokens*, integração com um *Authorization Server* e cuidado na recolha de métricas e *logs*. Ainda assim, este risco continua relevante para uma evolução futura em direção a ambientes de produção e cenários *multi-tenant*.
- **Âmbito e complexidade funcional:** O domínio das Gateways de IA inclui várias funcionalidades possíveis, como roteamento por custo, políticas avançadas de autorização, execução automática de ferramentas, suporte completo a **MCP**, cache semântica e gestão de quotas por utilizador. Implementar todas estas capacidades numa primeira versão aumentaria significativamente o risco de atrasos e instabilidade. A mitigação passou pela definição de um âmbito inicial mais controlado, focado na arquitetura base, nos *adapters* principais, na *pipeline* de *interceptors* e numa **Gateway** funcional construída sobre o **SDK**. As funcionalidades mais avançadas foram identificadas como trabalho futuro.

B.2 Planeamento

Semana	Período	Descrição
1	18 fev – 22 fev (parcial)	Estudo das APIs de inferência e protocolo MCP .
2	23 fev – 1 mar	Continuação da semana anterior e início da proposta.
3	2 mar – 8 mar	Entrega Proposta do projeto
4	9 mar – 15 mar	Configuração inicial da biblioteca, definição da arquitetura base e das interfaces.
5	16 mar – 22 mar	Integração com as APIs de inferência. Foco inicial em dois fornecedores estáveis.
6	23 mar – 29 mar	Integração do MCP no OmniAI Core . Invocação e registo dinâmico de ferramentas, gerindo o ciclo de <i>tool calling</i> .
7	30 mar – 5 abr	Implementação de despacho configurável de modelos e mecanismos de redundância (<i>fallback</i> e <i>retry</i>).
8	6 abr – 12 abr	Implementação dos mecanismos de segurança, como controlo de acesso, preparação do contexto e remoção de dados sensíveis.
9	13 abr – 19 abr	Conclusão das implementações anteriores.
10	20 abr – 26 abr	Apresentação de Progresso
11	27 abr – 3 mai	Início do desenvolvimento da aplicação final OmniAI Gateway . Exposição da Web API.
12	4 mai – 10 mai	Continuação da semana anterior e preparação das abstrações MCP para integração futura.
13	11 mai – 17 mai	Término de todas as APIs de comunicação para o exterior.
14	18 mai – 24 mai	Testes de integração do Core e da Gateway .
15	25 mai – 31 mai	Entrega da Versão beta
16	1 jun – 7 jun	Refinamento de testes a todos os módulos.
17	8 jun – 14 jun	Refinamento de código, desempenho e limpeza de bugs do sistema.
18	15 jun – 21 jun	Continuação da semana anterior e refinamento do relatório final.
19	22 jun – 28 jun 2026	Conclusão do relatório final.
20	29 jun – 5 jul 2026	Vistoria completa a todo o sistema e polimento de falhas para a entrega da Versão final.
21	6 jul – 11 jul 2026 (parcial)	Entrega Final do Projeto e Relatório

Tabela B.1: Planeamento semanal do projeto

Referências

- [1] OpenAI, “Openai api documentation.” [Online]. Available: <https://platform.openai.com/docs/>
- [2] Anthropic, “Anthropic messages api documentation.” [Online]. Available: <https://docs.anthropic.com/en/api/messages>
- [3] Google, “Gemini api documentation.” [Online]. Available: <https://ai.google.dev/docs>
- [4] IBM, “What is tool calling?” [Online]. Available: <https://www.ibm.com/think/topics/tool-calling>
- [5] DAIR.AI, “Function calling and tool use in LLM agents.” [Online]. Available: <https://www.promptingguide.ai/agents/function-calling>
- [6] KMP, “Kmp documentation.” [Online]. Available: <https://kotlinlang.org/multiplatform/>
- [7] A. D. Blog, “Hexagonal architecture: Understanding ports and adapters.” [Online]. Available: <https://medium.com/@akdevblog/hexagonal-architecture-understanding-ports-4020009e1aad>
- [8] GeeksforGeeks, “Java servlet filter.” [Online]. Available: <https://www.geeksforgeeks.org/java/java-servlet-filter/>
- [9] —, “Servlet - filterchain.” [Online]. Available: <https://www.geeksforgeeks.org/java/servlet-filterchain/>
- [10] Model Context Protocol, “Model context protocol specification.” [Online]. Available: <https://modelcontextprotocol.io>
- [11] Claude, “Get started with claude code.” [Online]. Available: <https://claude.com/product/claude-code>
- [12] Google Developers, “Gemini api documentation: Intro to function calling with gemini.” [Online]. Available: <https://ai.google.dev/gemini-api/docs/function-calling>
- [13] IBM, “What are large language models (LLMs)?” [Online]. Available: <https://www.ibm.com/think/topics/large-language-models>
- [14] NVIDIA, “Ai tokens explained.” [Online]. Available: <https://blogs.nvidia.com/blog/ai-tokens-explained/>

- [15] Groq, “Groq api documentation.” [Online]. Available: <https://console.groq.com/docs>
- [16] IBM, “What are agentic workflows?” [Online]. Available: <https://www.ibm.com/think/topics/agentic-workflows>
- [17] CloudZero, “Ai vendor lock-in: How ai is creating a new dependency problem.” [Online]. Available: <https://www.cloudzero.com/blog/ai-vendor-lock-in/>
- [18] S. P, “System design of api gateway.” [Online]. Available: <https://medium.com/@lazygeek78/system-design-of-api-gateway-e8924b71b7fb>
- [19] Vasanthan, “Ai gateway pattern: Centralized model access layer.” [Online]. Available: <https://medium.com/@vasanthancomrads/ai-gateway-pattern-centralized-model-access-layer-c5049e4f151f>
- [20] K. Stoney, “Building an ai gateway.” [Online]. Available: <https://karlstoney.com/building-an-ai-gateway/>
- [21] Berri AI, “LiteLLM: Call all llm apis using the openai format.” [Online]. Available: <https://www.litellm.ai/>
- [22] OpenRouter, “OpenRouter: A unified interface for llms.” [Online]. Available: <https://openrouter.ai/>
- [23] JetBrains, “Kotlin multiplatform documentation.” [Online]. Available: <https://www.jetbrains.com/help/kotlin-multiplatform-dev/get-started.html>
- [24] OpenAI, “Openai api documentation: Structured outputs and function calling (json schema).” [Online]. Available: <https://platform.openai.com/docs/guides/structured-outputs>
- [25] Anthropic, “Anthropic docs: Define tools.” [Online]. Available: <https://platform.claude.com/docs/en/agents-and-tools/tool-use/define-tools>
- [26] JSON Schema, “Json schema specification.” [Online]. Available: <https://json-schema.org/specification>
- [27] OpenAPI Initiative, “Openapi specification v3.0.3.” [Online]. Available: <https://spec.openapis.org/oas/v3.0.3>
- [28] Google, “Gemini api reference: Schema object (openapi 3.0 subset).” [Online]. Available: <https://ai.google.dev/api/caching?#Schema>
- [29] Ollama, “Ollama documentation.” [Online]. Available: <https://ollama.com/>
- [30] Google, “Google ai studio documentation.” [Online]. Available: <https://aistudio.google.com/app/docs>
- [31] Model Context Protocol, “Architecture overview.” [Online]. Available: <https://modelcontextprotocol.io/docs/learn/architecture>

- [32] —, “Kotlin sdk for model context protocol.” [Online]. Available: <https://github.com/modelcontextprotocol/kotlin-sdk>
- [33] Ktor, “Ktor serialization documentation.” [Online]. Available: <https://ktor.io/docs/welcome.html>
- [34] GeeksforGeeks, “Hexagonal architecture - system design.” [Online]. Available: <https://www.geeksforgeeks.org/system-design/hexagonal-architecture-system-design/>
- [35] Netflix Technology Blog, “Ready for changes with hexagonal architecture,” 2020. [Online]. Available: <https://netflixtechblog.com/ready-for-changes-with-hexagonal-architecture-b315ec967749>
- [36] H. Graça, “Ddd, hexagonal, onion, clean, cqrs, ... how i put it all together,” 2017. [Online]. Available: <https://herbertograca.com/2017/11/16/explicit-architecture-01-ddd-hexagonal-onion-clean-cqrs-how-i-put-it-all-together/>
- [37] Gradle, “Composite builds.” [Online]. Available: https://docs.gradle.org/current/userguide/composite_builds.html
- [38] Kotlin Serialization, “Kotlin serialization documentation.” [Online]. Available: <https://kotlinlang.org/docs/serialization.html>
- [39] Logto, “Logto documentation.” [Online]. Available: <https://docs.logto.io/>
- [40] PostgreSQL, “Postgresql documentation.” [Online]. Available: <https://www.postgresql.org/docs/>
- [41] OpenTelemetry, “What is opentelemetry?” [Online]. Available: <https://opentelemetry.io/docs/what-is-opentelemetry/>
- [42] Prometheus, “Prometheus documentation.” [Online]. Available: https://prometheus.io/docs/prometheus/latest/getting_started/
- [43] Grafana, “Grafana documentation.” [Online]. Available: <https://grafana.com/docs/>
- [44] GitLab, “Pipelines ci documentation.” [Online]. Available: <https://docs.gitlab.com/ci/pipelines/>
- [45] OpenTelemetry, “Opentelemetry protocol specification.” [Online]. Available: <https://opentelemetry.io/docs/specs/otlp/>
- [46] D. Hardt, “RFC 6749: The oauth 2.0 authorization framework.” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc6749>
- [47] M. Jones and D. Hardt, “RFC 6750: The oauth 2.0 authorization framework: Bearer token usage.” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc6750>
- [48] OAuth.com, “The resource server.” [Online]. Available: <https://www.oauth.com/oauth2-servers/the-resource-server/>

- [49] M. Jones, N. Sakimura, and J. Bradley, “RFC 8414: Oauth 2.0 authorization server metadata.” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc8414>
- [50] M. Jones, J. Bradley, and N. Sakimura, “RFC 7519: Json web token (JWT).” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc7519>
- [51] M. Jones, “RFC 7517: Json web key (JWK).” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc7517>
- [52] M. Jones, J. Bradley, and N. Sakimura, “RFC 7515: Json web signature (JWS).” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc7515>
- [53] J. Richer, “RFC 7662: Oauth 2.0 token introspection.” [Online]. Available: <https://datatracker.ietf.org/doc/html/rfc7662>
- [54] Keycloak, “Keycloak documentation.” [Online]. Available: <https://www.keycloak.org/documentation>
- [55] Microsoft, “Authentication vs. authorization.” [Online]. Available: <https://learn.microsoft.com/en-us/entra/identity-platform/authentication-vs-authorization>
- [56] Identity Beyond Borders, “The four horsemen of authorization: The p’s, pep, pdp, pap, and pip.” [Online]. Available: <https://medium.com/identity-beyond-borders/the-four-horsemen-of-authorization-the-p-ps-pep-pdp-pap-and-pip-42717e445ce7>
- [57] Cloudflare, “O que e limitacao de taxa?” [Online]. Available: <https://www.cloudflare.com/pt-br/learning/bots/what-is-rate-limiting/>
- [58] Microsoft, “Circuit breaker pattern.” [Online]. Available: <https://learn.microsoft.com/azure/architecture/patterns/circuit-breaker>
- [59] Itau Tecnologia, “Compreendendo o conceito de circuit breaker e sua aplicacao em arquitetura de microsservicos.” [Online]. Available: <https://medium.com/@itautecnologia/compreendendo-o-conceito-de-circuit-breaker-e-sua-aplica%C3%A7%C3%A3o-em-arquitetura-de-microsservi%C3%A7os-108dc2d1be2c>
- [60] TreinaWeb, “O que e circuit breaker?” [Online]. Available: <https://www.treinaweb.com.br/blog/o-que-e-circuit-breaker>
- [61] T. Tombas, “Building resilient ai systems: Understanding model-level fallback mechanisms.” [Online]. Available: <https://medium.com/@tombastaner/building-resilient-ai-systems-understanding-model-level-fallback-mechanisms-436cf636045f>
- [62] Portkey, “Fallbacks.” [Online]. Available: <https://portkey.ai/docs/product/ai-gateway/fallbacks>
- [63] OIDC discovery, “Oidc discovery documentation.” [Online]. Available: <https://cloud.ibm.com/docs/appid?topic=appid-discovery>

- [64] Resource Server, “Resource server.” [Online]. Available: <https://docs.spring.io/spring-security/reference/servlet/oauth2/resource-server/index.html>
- [65] PKCE, “Pkce documentation.” [Online]. Available: <https://auth0.com/docs/get-started/authentication-and-authorization-flow/authorization-code-flow-with-pkce>
- [66] Open Code, “Open code documentation.” [Online]. Available: <https://opencode.ai/docs/>
- [67] LibreChat, “Librechat documentation.” [Online]. Available: <https://www.librechat.ai/docs/documentation>
- [68] Dify, “Dify documentation.” [Online]. Available: <https://docs.dify.ai/en/use-dify/getting-started/introduction>